

# 基于信号处理的孤立数字语音识别实验报告

于沛龙 景序 封宇凡 孟德轩

2026 年 5 月

## 摘要

本实验面向数字 0-9 的孤立词语音识别任务，基于 7 位说话人共 70 段语音（训练集 speaker1-5 共 50 条，验证集 speaker6-7 共 20 条），完成了语音信号分析、MFCC 特征提取、分类识别和噪声鲁棒性测试。在信号处理方面，对语音进行端点检测、预加重、分帧加窗和短时傅里叶分析，提取 13 维 MFCC 及其一阶、二阶动态差分特征（共 39 维）。在分类方面，分别采用基于 26 维统计特征的 KNN 基线、基于 39 维帧级序列特征的 GMM 模型以及基于 MFCC 动态特征图的卷积神经网络（CNN）进行数字分类。实验结果表明，纯净语音条件下 GMM 与 CNN 均达到 100.0% 识别准确率；在混合噪声（白噪声、1/f 粉红噪声与 50 Hz 工频干扰）条件下，各模型识别性能随信噪比降低而下降，其中 GMM 是传统方法中最稳定的方案，CNN 在中高 SNR 区间保持了较好的识别性能。实验验证了信号处理方法在语音识别中的有效性，同时也揭示了小样本数据集下不同方法的优劣与局限。

**关键词：**孤立词语音识别；MFCC；KNN；GMM；CNN；噪声鲁棒性；信号与系统

# 目录

|                                 |           |
|---------------------------------|-----------|
| <b>一、 实验目的与数据集</b>              | <b>4</b>  |
| 1.1 实验背景与目的 . . . . .           | 4         |
| 1.2 数据集 . . . . .               | 4         |
| 1.3 实验评价设置 . . . . .            | 5         |
| <b>二、 语音信号分析</b>                | <b>5</b>  |
| 2.1 时域波形 . . . . .              | 5         |
| 2.2 频域分析 . . . . .              | 5         |
| 2.3 短时傅里叶变换与语谱图 . . . . .       | 6         |
| <b>三、 特征提取</b>                  | <b>6</b>  |
| 3.1 预加重 . . . . .               | 7         |
| 3.2 分帧、加窗与短时傅里叶变换 . . . . .     | 7         |
| 3.3 梅尔滤波器组 . . . . .            | 7         |
| 3.4 对数压缩与离散余弦变换 . . . . .       | 8         |
| 3.5 动态特征 . . . . .              | 8         |
| 3.6 与信号与系统课程的关联 . . . . .       | 9         |
| <b>四、 识别方法</b>                  | <b>9</b>  |
| 4.1 MFCC 统计特征与 KNN 基线 . . . . . | 10        |
| 4.2 MFCC 序列特征与 GMM 模型 . . . . . | 11        |
| 4.3 MFCC 动态特征图与 CNN . . . . .   | 12        |
| 4.4 三种方法的对比 . . . . .           | 14        |
| <b>五、 实验结果与噪声鲁棒性分析</b>          | <b>14</b> |
| 5.1 纯净语音识别结果 . . . . .          | 14        |
| 5.2 噪声添加方法与评价指标 . . . . .       | 15        |
| 5.3 KNN 基线的噪声鲁棒性 . . . . .      | 16        |
| 5.4 GMM 序列模型的噪声鲁棒性 . . . . .    | 16        |
| 5.5 CNN 的噪声鲁棒性 . . . . .        | 17        |
| <b>六、 结果讨论与结论</b>               | <b>19</b> |
| 6.1 综合结果比较 . . . . .            | 19        |
| 6.2 噪声鲁棒性分析 . . . . .           | 19        |
| 6.3 与信号与系统课程知识的联系 . . . . .     | 20        |
| 6.4 实验局限性 . . . . .             | 21        |
| 6.5 结论 . . . . .                | 21        |

|         |    |
|---------|----|
| 目录      | 3  |
| 七、 团队分工 | 22 |

# 一、实验目的与数据集

## 1.1 实验背景与目的

孤立词语音识别是语音识别领域的基础任务之一，其目标是将说话人发出的单个词语（如数字、命令词）映射为对应的文本标签。本实验面向数字 0–9 的孤立词语音识别任务，完成从语音信号分析、特征提取、模型训练到噪声鲁棒性评估的完整流程。

从信号与系统的视角看，语音信号是典型的离散时间非平稳信号，整个识别流程涉及多个课程核心概念<sup>[1]</sup>：

- 预加重等效于一阶 FIR 高通滤波器，用于补偿语音高频部分的衰减；
- 分帧加窗利用短时平稳假设，将非平稳语音信号转化为准平稳帧序列；
- 短时傅里叶变换（STFT）实现信号的时频域联合分析；
- 梅尔滤波器组模拟人耳的非线性频率感知特性，体现了频域加权的思想；
- 离散余弦变换（DCT）用于特征去相关与压缩，是正交变换的典型应用。

通过对比不同特征表示和分类模型在纯净及含噪条件下的识别性能，本实验旨在加深对信号处理技术在语音识别中应用的理解，并探索传统方法与深度学习方法在小样本数据集下的优劣。

## 1.2 数据集

实验数据集包含 7 位说话人，每人分别朗读数字 0–9 一遍，共计 70 段语音。所有语音以 16 kHz 采样率、单声道格式存储。原始语音通过基于短时能量的端点检测算法自动切分为独立发音片段。

为保证训练集与验证集之间无说话人重叠，数据集按照说话人身份进行划分，如表 1 所示。

表 1: 数据集划分

| 划分  | 说话人         | 样本数 |
|-----|-------------|-----|
| 训练集 | speaker 1–5 | 50  |
| 验证集 | speaker 6–7 | 20  |

训练集每数字包含 5 个不同说话人的发音样本，验证集每数字包含 2 个不同于训练说话人的发音样本。说话人不重叠的划分方式能够更真实地反映模型的泛化能力，避免模型仅记忆特定说话人的声纹特征。

### 1.3 实验评价设置

在纯净语音条件下，以识别准确率和混淆矩阵作为主要评价指标，用以评估各模型对不同数字的区分能力。

在噪声鲁棒性测试中，向验证集语音叠加混合噪声，噪声由以下三种成分等功率混合并经 RMS 归一化得到：

- 高斯白噪声；
- 1/f 粉红噪声（频域法生成）；
- 50 Hz 工频干扰（正弦波）。

测试设置 7 个信噪比（SNR）等级：-10 dB、-5 dB、0 dB、5 dB、10 dB、15 dB、20 dB，覆盖从强噪声到弱噪声的完整范围。通过考察各模型在不同 SNR 下的识别准确率变化趋势，评估其噪声鲁棒性。

## 二、 语音信号分析

### 2.1 时域波形

语音信号在时域中表现为幅度随时间变化的离散序列。时域波形可以反映语音的能量包络、发音起止位置以及静音段分布，因此可用于端点检测<sup>[2]</sup>。




图 1: 语音信号时域波形

### 2.2 频域分析

对离散语音信号作快速傅里叶变换（FFT），可得到其整体频率能量分布。离散傅里叶变换定义为

$$X[k] = \sum_{n=0}^{N-1} x[n]e^{-j2\pi kn/N}. \quad (1)$$

频谱图能够反映语音信号的主要频率成分和共振峰分布，但由于语音信号是典型非平稳信号，整体 FFT 无法表示频谱随时间的动态变化。




图 2: 语音信号 FFT 幅度谱

### 2.3 短时傅里叶变换与语谱图

为分析语音信号的时变频谱特性，实验采用短时傅里叶变换（STFT）。其基本思想是对信号进行分帧和加窗，在每一短时帧内近似认为信号平稳，再分别进行傅里叶变换：

$$X(m, k) = \sum_{n=0}^{N-1} x[n]w[n-m]e^{-j2\pi kn/N}. \quad (2)$$

本实验采用 25 ms Hamming 窗和 10 ms 帧移。语谱图横轴为时间，纵轴为频率，颜色表示能量强弱，可以同时展示语音的时间、频率和能量变化。




图 3: 语音信号 STFT 语谱图

## 三、 特征提取

语音信号经过预处理和短时分析后，需要进一步提取能够表征不同数字之间声学差异的特征。梅尔频率倒谱系数（Mel-Frequency Cepstral Coefficients, MFCC）是语音识别中最广泛应用的特征之一，其设计模拟了人耳对声音的非线性感知特性。本节详细介绍 MFCC 特征提取的完整流程，包括预加重、分帧加窗、FFT 与功率谱、梅尔滤波、对数压缩与离散余弦变换，以及动态特征的构建。

### 3.1 预加重

语音信号在唇辐射和空气传输过程中, 高频分量会自然衰减。为补偿这一效应, 首先对离散语音信号  $x[n]$  进行预加重 (pre-emphasis), 即通过一阶 FIR 高通滤波器:

$$y[n] = x[n] - \alpha x[n-1], \quad (3)$$

其中预加重系数  $\alpha = 0.97$ 。该滤波器的作用是增强信号的高频成分, 使频谱在高频段更加平坦, 有利于后续的频谱分析。从信号与系统的角度看, 该系统的传递函数为  $H(z) = 1 - \alpha z^{-1}$ , 是一个简单的一阶高通 FIR 滤波器。

### 3.2 分帧、加窗与短时傅里叶变换

语音信号是典型的非平稳信号, 其统计特性随时间变化。但在较短的时段 (约 20–30 ms) 内, 发音器官的运动相对缓慢, 信号可近似视为平稳。基于这一短时平稳假设, 对预加重后的信号进行分帧处理: 采用窗长为 25 ms 的 Hamming 窗, 帧移为 10 ms。在 16 kHz 采样率下, 窗长对应  $N = 400$  个采样点, 帧移对应 160 个采样点。

Hamming 窗的时域表达式为

$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right), \quad 0 \leq n \leq N-1. \quad (4)$$

加窗可以减小帧边界处的不连续性, 抑制频谱泄漏。

对每一帧加窗后的信号进行  $K$  点 FFT, 得到短时幅度谱  $|X(m, k)|$ , 进而计算功率谱  $|X(m, k)|^2$ 。关于 STFT 的详细讨论见语音信号分析一节。

### 3.3 梅尔滤波器组

人耳对声音频率的感知是非线性的: 在低频区域, 人耳能够分辨较细微的频率差异; 而在高频区域, 频率分辨率则相对较低。梅尔 (Mel) 尺度正是为了模拟这一感知特性而提出的一种频率映射, 其与物理频率  $f$  (Hz) 的近似关系为

$$\text{Mel}(f) = 2595 \log_{10}\left(1 + \frac{f}{700}\right). \quad (5)$$

在梅尔尺度上等间距地放置一组三角滤波器, 再映射回线性频率轴, 即构成梅尔滤波器组。梅尔滤波器在低频段分布密集、在高频段分布稀疏, 体现了人耳的非线性频率分辨率。

本实验采用 40 个三角梅尔滤波器, 频率范围为 20 Hz 至 7600 Hz (对应 16 kHz 采样的奈奎斯特频率以下)。每一帧的功率谱通过梅尔滤波器组后, 得到 40 维的对数梅尔能量。

### 3.4 对数压缩与离散余弦变换

将梅尔滤波器组的输出取对数，一方面模拟人耳对响度的对数感知特性，另一方面压缩动态范围，使特征对输入能量的绝对大小不敏感：

$$S(m, l) = \log \left( \sum_{k=0}^{K-1} |X(m, k)|^2 \cdot H_l[k] \right), \quad (6)$$

其中  $H_l[k]$  为第  $l$  个梅尔滤波器的频率响应， $l = 0, 1, \dots, L-1$ ， $L = 40$ 。

对数梅尔能量各维度之间存在较强的相关性。为降低特征维度并去除相关性，对  $S(m, l)$  沿滤波器轴进行离散余弦变换（DCT）：

$$c(m, i) = \sum_{l=0}^{L-1} S(m, l) \cos \left[ \frac{\pi i}{L} \left( l + \frac{1}{2} \right) \right], \quad i = 0, 1, \dots, N_{\text{mfcc}} - 1. \quad (7)$$

DCT 是一种正交变换，能够将能量集中到少数低阶系数上，同时使各阶倒谱系数近似不相关。保留前  $N_{\text{mfcc}} = 13$  个 DCT 系数，即为该帧的 MFCC 特征。

值得注意的是，第 0 阶系数  $c(m, 0)$ （常记为 C0）主要反映该帧的整体能量，数值通常远大于其余系数。在后续特征可视化中，为避免 C0 掩盖其他倒谱系数的细节结构，13 维 MFCC 图在绘制时省略 C0，仅显示 C1–C12。




图 4: 13 维 MFCC 特征图（可视化时省略 C0，仅显示 C1–C12）。横轴为帧序号，纵轴为 MFCC 系数阶数，颜色表示系数值的大小。

### 3.5 动态特征

静态 MFCC 仅反映当前帧的频谱包络信息，无法刻画语音信号随时间变化的动态特性。为此，在 13 维静态 MFCC 的基础上，分别计算一阶差分（Delta,  $\Delta$ ）和二阶差分（Delta-Delta,  $\Delta^2$ ）：

$$\Delta_t = \frac{\sum_{n=1}^{N_d} n (c_{t+n} - c_{t-n})}{2 \sum_{n=1}^{N_d} n^2}, \quad (8)$$



其中  $c_t$  为第  $t$  帧的 MFCC 向量， $N_d$  为差分窗口半径（本实验取  $N_d = 2$ ）。 $\Delta^2$  以同样的方式在  $\Delta$  序列上计算得到。

最终，每一帧的特征向量由 13 维静态 MFCC、13 维  $\Delta$  和 13 维  $\Delta^2$  拼接而成，共计 39 维帧级特征。动态特征的引入使模型能够同时利用频谱包络的静态信息和帧间变化的动态信息，从而更好地建模语音的时序演变规律。




图 5: 39 维 MFCC +  $\Delta$  +  $\Delta^2$  特征图。上段为 13 维静态 MFCC（含 C0），中段为 13 维  $\Delta$ ，下段为 13 维  $\Delta^2$ 。横轴为帧序号，纵轴为系数阶数。

图 4 和图 5 分别展示了同一语音段在两种特征表示下的可视化结果。13 维特征图（图 4）聚焦于静态频谱包络的时变模式，不同数字的 MFCC 在特定系数阶数上呈现出差异化的能量分布；39 维特征图（图 5）则进一步整合了动态信息， $\Delta$  和  $\Delta^2$  分量反映了频谱变化的速率与加速度，为后续的分类模型提供了更丰富的时序判别依据。

### 3.6 与信号与系统课程的关联

MFCC 特征提取流程与信号与系统课程的知识体系紧密相关。预加重对应一阶 FIR 滤波器的设计与频率响应分析；分帧加窗涉及信号截断与频谱泄漏问题，是离散时间信号处理的重要内容；FFT 和功率谱估计是频域分析的核心工具，在语音信号分析一节中已有详细讨论；梅尔滤波器组体现了频域加权的思想，本质上是对功率谱的频域滤波；对数运算实现动态范围压缩，与信号的非线性变换相关；DCT 作为正交变换，具有能量集中和去相关的优良性质，是信号表示理论中的典型方法。这些信号处理技术的有机结合，构成了从原始语音波形到紧凑声学特征表示的关键桥梁。

## 四、 识别方法

在完成语音信号分析和 MFCC 特征提取之后，需要设计分类模型将特征向量映射为数字标签 0–9。本实验采用三种不同类型的分类方法：基于统计特征聚合的 K 近邻（KNN）基线方法、基于帧级序列概率建模的高斯混合模型（GMM），以及基于卷积神

神经网络（CNN）的深度学习方法。三种方法在输入特征形式、建模策略和模型复杂度上各有不同，构成了从简单到复杂的对比实验。

#### 4.1 MFCC 统计特征与 KNN 基线

KNN 是一种简单直观的非参数分类方法，适合作为小样本语音识别任务的基线。为使变长帧序列能够输入基于固定长度向量的 KNN 分类器，本实验对每段语音的 13 维 MFCC 帧级特征沿时间轴分别计算均值和标准差，拼接为 26 维固定长度特征向量：

$$\mathbf{f} = [\boldsymbol{\mu}, \boldsymbol{\sigma}], \quad \boldsymbol{\mu} = \frac{1}{T} \sum_{t=1}^T \mathbf{c}_t, \quad \boldsymbol{\sigma} = \sqrt{\frac{1}{T} \sum_{t=1}^T (\mathbf{c}_t - \boldsymbol{\mu})^2}, \quad (9)$$

其中  $\mathbf{c}_t \in \mathbb{R}^{13}$  为第  $t$  帧的 MFCC 向量， $T$  为该语音段的总帧数。

在分类之前，使用 StandardScaler 对特征进行标准化，使各维特征具有零均值和单位方差。分类器采用  $k = 1$  的最近邻分类器，距离度量为欧氏距离。由于训练集中每个类别包含多个说话人的样本，1-NN 实际上是在全部训练样本中寻找最近邻：

$$i^* = \arg \min_i \|\mathbf{f} - \mathbf{f}_i^{\text{train}}\|_2, \quad \hat{y} = y_i^{\text{train}}|_{i=i^*}. \quad (10)$$

该方法的优点在于简单、可解释，且无需训练过程，非常适合小样本场景。然而，均值与标准差的统计池化操作丢弃了帧之间的时序顺序信息——两段发音顺序完全不同的语音可能具有相近的统计量，从而导致误判。此外，尝试将 39 维动态特征（MFCC +  $\Delta$  +  $\Delta^2$ ）也以同样方式池化后输入 KNN 时，验证准确率反而下降，推测原因是高维特征下统计池化加剧了信息损失，欧氏距离的判别能力也随之减弱。




图 6: KNN 纯净语音混淆矩阵（准确率 80.0%，16/20）。主要混淆为  $0 \rightarrow 7$ 、 $2 \rightarrow 8$ 、 $4 \rightarrow 3$ 、 $6 \rightarrow 9$ ，表明统计特征的判别力不足以区分部分发音相近的数字对。

## 4.2 MFCC 序列特征与 GMM 模型

GMM 通过对每一类数字的概率密度进行参数化建模，能够直接处理变长帧序列，避免了将语音“压缩”为固定统计量的过程。本实验为每个数字类别  $c \in \{0, \dots, 9\}$  分别训练一个 GMM，模型参数为  $\lambda_c = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^K$ 。

输入特征为 39 维帧级特征  $\mathbf{x}_t \in \mathbb{R}^{39}$ （13 维 MFCC + 13 维  $\Delta$  + 13 维  $\Delta^2$ ）。在训练前，对特征进行倒谱均值方差归一化（Cepstral Mean and Variance Normalization, CMVN），以减小信道差异和录音环境的影响。每个 GMM 包含  $K = 4$  个高斯分量，协方差矩阵约束为对角形式，以在参数量和建模能力之间取得平衡。模型参数通过期望最大化（EM）算法从训练样本中估计。

对于一段包含  $T$  帧的语音  $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_T\}$ ，其属于类别  $c$  的对数似然为

$$\log p(\mathbf{X} | \lambda_c) = \sum_{t=1}^T \log \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_t | \mu_k, \Sigma_k). \quad (11)$$

最终判决为对数似然最大的类别：

$$\hat{y} = \arg \max_c \log p(\mathbf{X} | \lambda_c). \quad (12)$$

GMM 方法的主要优势在于：保留完整的帧序列信息，不进行统计池化，能够充分地利用 MFCC 动态特征所反映的帧级分布与局部变化；对角协方差假设在参数量可控的前提下，仍能有效建模各类数字在特征空间中的分布。在小样本条件下，GMM

的表现尤为突出。




图 7: GMM 纯净语音混淆矩阵（准确率 100.0%，20/20）。20 条验证样本全部识别正确，表明 GMM 结合 39 维动态特征在小样本场景下具有优异的分类性能。

### 4.3 MFCC 动态特征图与 CNN

为进一步探索深度学习方法在小样本语音识别任务中的潜力，本实验采用轻量级卷积神经网络（CNN）进行数字分类。与 KNN 和 GMM 不同，CNN 将 39 维 MFCC 帧级特征排列为  $39 \times T$  的二维特征图，并将其视为单通道图像输入网络。其中 39 维特征由 13 维静态 MFCC、13 维一阶差分  $\Delta$  和 13 维二阶差分  $\Delta^2$  拼接得到， $T$  表示语音片段对应的帧数。卷积网络通过局部卷积核在时间轴和特征轴上滑动，自动学习 MFCC 特征图中的局部时频模式。

CNN 的总体可训练参数数量为 102,522，结构如表 2 所示。网络包含 4 个卷积块，通道数从 1 逐步扩展至 128，每个卷积块由 Conv2d（ $3 \times 3$  卷积核）、BatchNorm2d 和 ReLU 激活函数组成。前三个卷积块后各接一个  $2 \times 2$  最大池化层，以逐步降低特征图尺寸并扩大感受野；第四个卷积块后使用自适应平均池化将特征图统一压缩至  $2 \times 2$ ，随后经 Flatten 展开为 512 维向量，再通过 Dropout（ $p = 0.3$ ）和全连接层输出 10 类数字的分类结果。

表 2: CNN 网络结构

| 层                             | 输出尺寸                      | 参数量     |
|-------------------------------|---------------------------|---------|
| ConvBlock (1 → 16) + MaxPool  | $16 \times 19 \times T/2$ | 176     |
| ConvBlock (16 → 32) + MaxPool | $32 \times 9 \times T/4$  | 4,672   |
| ConvBlock (32 → 64) + MaxPool | $64 \times 4 \times T/8$  | 18,560  |
| ConvBlock (64 → 128)          | $128 \times 4 \times T/8$ | 73,984  |
| AdaptiveAvgPool2d + Flatten   | 512                       | 0       |
| Dropout + Linear(512, 10)     | 10                        | 5,130   |
| 总计                            |                           | 102,522 |

训练采用 AdamW 优化器，学习率为 0.001，权重衰减为 0.0001，batch size 为 16，最大训练轮次为 500。为缓解小样本条件下的过拟合风险，网络中引入 BatchNorm、Dropout 和早停机制。其中早停 patience 设置为 160 个轮次，最佳验证准确率出现在第 54 轮，最终纯净验证集准确率为 100.0%。需要说明的是，本实验 CNN 训练过程中未额外采用随机增益扰动、随机时间平移或随机噪声增强；模型主要依靠 MFCC 动态特征图、卷积局部建模能力以及 Dropout/早停等正则化策略提升泛化能力。




图 8: CNN 纯净语音混淆矩阵（准确率 100.0%，20/20）。20 条验证样本全部识别正确，说明卷积网络能够从 MFCC 动态特征图中学习到有效的局部时频判别模式。

CNN 方法的主要优势在于能够通过卷积核自动学习 MFCC 特征图中的局部时频结构，不需要人工定义统计量或概率分布假设。与 KNN 的全局统计池化相比，CNN 保留了特征图中的局部时序变化；与 GMM 的逐类概率建模相比，CNN 具有更强的非线性表示能力。不过，深度学习模型的统计可靠性仍受训练集规模限制；在本实验仅 50 条训练样本的条件下，CNN 结果应结合噪声测试趋势和小样本局限共同分析。

4.4 三种方法的对比

表 3 从输入特征、建模方式和主要特点三个维度对三种方法进行了总结。

表 3: 三种识别方法的对比

| 方法  | 输入特征                                                 | 建模方式                              | 主要特点                                |
|-----|------------------------------------------------------|-----------------------------------|-------------------------------------|
| KNN | 26 维统计特征<br>(13 维 MFCC 均值 + 标准差)                     | 1-NN, 欧氏距离                        | 简单可解释, 无需训练;<br>但统计池化丢失时序信息         |
| GMM | 39 维帧级序列特征<br>(MFCC + $\Delta$ + $\Delta^2$ )        | 4 分量对角协方差 GMM,<br>最大对数似然判决        | 保留变长帧序列, 适合小样本;<br>概率建模稳定, 适合帧级分布建模 |
| CNN | $39 \times T$ 特征图<br>(MFCC + $\Delta$ + $\Delta^2$ ) | 4 层卷积网络, 102k 参数,<br>Dropout + 早停 | 自动学习局部时频模式;<br>表示能力强, 但需注意小样本局限     |

三种方法从不同角度解决了“如何利用 MFCC 特征进行数字分类”这一问题:KNN 最为简单, 以统计聚合换取固定维度输入; GMM 在保留序列信息和控制模型复杂度之间取得良好平衡, 尤其适合本实验的小样本场景; CNN 具有更强的表示学习能力, 能够从二维 MFCC 动态特征图中自动提取局部时频模式, 但其结果仍需结合小样本数据集的统计局限进行理解。三者在纯净语音条件下的准确率比较和噪声鲁棒性分析将在下一章详细讨论。

五、实验结果与噪声鲁棒性分析

本节对三种识别方法在纯净语音和混合噪声条件下的实验结果进行比较。纯净语音实验用于评估模型在理想条件下的基本分类能力; 噪声鲁棒性实验则通过在验证集语音中叠加不同强度的混合噪声, 考察识别系统在实际复杂环境下的稳定性。

5.1 纯净语音识别结果

在无噪声条件下, 三种方法均使用 speaker 6-7 的 20 条验证语音进行测试。除整体识别准确率外, 本文还使用混淆矩阵分析不同数字类别之间的误判关系。混淆矩阵的行列分别对应真实类别与预测类别, 矩阵中非对角元素能够反映模型容易混淆的数字对<sup>[3]</sup>。表 4 总结了三种方法的输入特征与识别准确率。其中, KNN 使用 13 维 MFCC 的均值和标准差构成 26 维统计特征; GMM 使用 39 维 MFCC +  $\Delta$  +  $\Delta^2$  帧级序列特征; CNN 则将同样的 39 维动态特征组织为二维特征图进行卷积分类。

表 4: 纯净语音条件下三种识别方法的准确率比较

| 方法                                 | 输入特征                     | 准确率    |
|------------------------------------|--------------------------|--------|
| MFCC-stat + KNN                    | 26 维统计特征                 | 80.0%  |
| MFCC + $\Delta$ + $\Delta^2$ + GMM | 39 维帧级序列特征               | 100.0% |
| CNN                                | $39 \times T$ MFCC 动态特征图 | 100.0% |

从结果可以看出, GMM 与 CNN 在纯净语音条件下均达到 100.0% 的验证准确率, 20 条验证样本全部识别正确。其中, GMM 说明在小样本条件下, 用概率生成模型直接建模变长帧序列是有效的; CNN 则说明卷积网络能够从 MFCC 动态特征图中学习到有效的局部时频判别模式。KNN 的准确率为 80.0%, 主要混淆包括  $0 \rightarrow 7$ 、 $2 \rightarrow 8$ 、 $4 \rightarrow 3$ 、 $6 \rightarrow 9$ , 反映出均值/标准差统计池化会损失部分发音过程中的时间顺序信息。

## 5.2 噪声添加方法与评价指标

噪声鲁棒性测试中, 保持训练好的模型参数不变, 仅对验证集语音添加噪声后重新识别。混合噪声由高斯白噪声、 $1/f$  粉红噪声和 50 Hz 工频干扰组成。其中, 白噪声近似覆盖全频段, 会整体抬高频谱噪声底;  $1/f$  噪声能量更集中于低频区域, 容易与语音中的低频共振峰重叠; 50 Hz 工频干扰则对应实际采集系统中常见的窄带周期性干扰。

设干净语音为  $x[n]$ , 归一化后的混合噪声为  $v[n]$ 。为了得到目标信噪比  $\text{SNR}_{\text{dB}}$ , 首先计算两者平均功率

$$P_x = \frac{1}{N} \sum_{n=0}^{N-1} x^2[n], \quad P_v = \frac{1}{N} \sum_{n=0}^{N-1} v^2[n]. \quad (13)$$

随后令噪声缩放系数为

$$\alpha = \sqrt{\frac{P_x}{P_v \cdot 10^{\text{SNR}_{\text{dB}}/10}}}, \quad (14)$$

并构造带噪语音

$$x_{\text{noisy}}[n] = x[n] + \alpha v[n]. \quad (15)$$

KNN 与 GMM 在  $-10$  dB 至  $20$  dB 的 7 个 SNR 等级下测试, 每个等级重复生成 20 次随机噪声, 并统计识别准确率的均值和标准差。CNN 使用更细的混合噪声 SNR 网络进行测试, SNR 范围扩展至  $30$  dB, 用于观察模型在不同噪声强度下的变化趋势。由于 CNN 曲线不是 KNN/GMM 的同一套 20 次重复均值实验, 因此下文主要比较趋势和最低可用 SNR, 而不作严格统计显著性比较。

### 5.3 KNN 基线的噪声鲁棒性

图 9 给出了 KNN 基线在不同 SNR 下的识别准确率曲线。可以看到，KNN 在带噪条件下性能下降明显。当 SNR 较低时，准确率接近随机猜测水平；即使 SNR 提升到 20 dB，平均准确率也仅恢复到约 50%，仍明显低于纯净语音下 80.0% 的准确率。




图 9: KNN 基线在混合噪声下的准确率-SNR 曲线。曲线为 20 次重复实验的平均准确率，误差棒表示标准差。

造成这一现象的主要原因在于，KNN 所使用的均值/标准差统计特征对噪声扰动较为敏感。噪声会改变各帧 MFCC 的整体分布，进而影响全局均值和标准差；同时，KNN 采用欧氏距离进行最近邻匹配，距离度量本身没有显式区分语音结构变化与噪声扰动。因此，在带噪条件下，原本相近的同类样本可能被拉远，不同类样本也可能因噪声而意外接近，导致分类边界不稳定。

从最低可用 SNR 的角度看，在本实验设置的  $-10$  dB 至  $20$  dB 范围内，KNN 没有达到 90% 以上准确率，说明其只能作为纯净或弱干扰条件下的简单基线，不适合作为主要鲁棒识别方案。

### 5.4 GMM 序列模型的噪声鲁棒性

图 10 给出了 GMM 模型在混合噪声下的准确率-SNR 曲线，表 5 给出了对应的 20 次重复均值与标准差。与 KNN 相比，GMM 的性能随 SNR 提升呈现更加稳定的上升趋势。在低 SNR 条件下，噪声仍会显著破坏 MFCC 特征，使模型难以可靠区分数字类别；但当 SNR 提升到中高区间后，GMM 的准确率提升明显，并在 20 dB 时达到 91.25%。



表 5: GMM 在不同 SNR 下的噪声鲁棒性结果 (20 次重复)

| SNR (dB) | 平均准确率  | 标准差                    |
|----------|--------|------------------------|
| -10      | 0.1000 | $1.39 \times 10^{-17}$ |
| -5       | 0.1575 | 0.0426                 |
| 0        | 0.3800 | 0.0731                 |
| 5        | 0.5575 | 0.0729                 |
| 10       | 0.7250 | 0.0433                 |
| 15       | 0.8525 | 0.0460                 |
| 20       | 0.9125 | 0.0311                 |




图 10: GMM 序列模型在混合噪声下的准确率-SNR 曲线。每个 SNR 重复 20 次，曲线展示平均准确率，误差棒表示标准差。

GMM 相比 KNN 更鲁棒，主要有三方面原因。第一，GMM 直接利用帧级序列特征，而不是将整段语音压缩为单一统计向量，因此保留了更多时间局部结构。第二，MFCC +  $\Delta$  +  $\Delta^2$  同时刻画频谱包络及其动态变化，使模型能够利用语音随时间演化的模式进行判别。第三，CMVN 能够减小整体能量、信道和录音条件差异对倒谱特征的影响，从而在一定程度上削弱噪声造成的全局偏移。

根据实验结果，若以 90% 准确率作为较高识别率标准，GMM 在测试范围内能够达到该标准的最低 SNR 为 20 dB。这表明 GMM 是本实验传统方法中综合表现最稳定的方案，但在强噪声环境下仍存在明显性能下降。

## 5.5 CNN 的噪声鲁棒性

图 11 展示了 CNN 在混合噪声条件下的准确率-SNR 曲线，表 6 给出了对应的细粒度 SNR 测试结果。在纯净验证集上，CNN 的识别准确率达到 100.0%。在带噪条

件下，CNN 准确率随 SNR 提升整体上升：-10 dB 时准确率为 20%，0 dB 时提升到 60%，10 dB 时达到 85%，并在 12.5 dB 首次达到 90%；25 dB 时达到 100%。

表 6: CNN 在混合噪声下不同 SNR 的识别准确率

| SNR/dB | -10 | -7.5 | -5 | -2.5 | 0  | 2.5 | 5  | 7.5 |
|--------|-----|------|----|------|----|-----|----|-----|
| 准确率/%  | 20  | 30   | 40 | 40   | 60 | 65  | 70 | 80  |

| SNR/dB | 10 | 12.5 | 15 | 17.5 | 20 | 22.5 | 25  | 30 |
|--------|----|------|----|------|----|------|-----|----|
| 准确率/%  | 85 | 90   | 90 | 95   | 90 | 95   | 100 | 95 |




图 11: CNN 在混合噪声下的准确率-SNR 曲线。该曲线采用更细 SNR 网格，主要用于观察准确率随 SNR 变化的趋势。

CNN 的优势在于能够通过卷积核学习 MFCC 特征图中的局部时频结构，而不是依赖人工定义的全局统计量或单帧概率密度。在中高 SNR 区间，语音信号的主要谱包络和动态变化仍能在 MFCC 特征图中保留，卷积网络因而能够利用局部时频模式完成分类。需要注意的是，本实验 CNN 训练阶段未专门引入随机噪声增强，因此其带噪结果不应简单归因于训练时的噪声适配，而应理解为 MFCC 动态特征、卷积结构和池化机制共同作用下的结果。同时，由于训练集仅有 50 条语音，验证集也仅有 20 条语音，CNN 的细粒度 SNR 曲线仍可能受到单次噪声抽样和小样本验证集的影响。因此，本报告将 CNN 曲线主要作为深度学习路线的趋势参考，不将其与 KNN/GMM 的 20 次重复均值曲线作严格统计显著性比较。

## 六、 结果讨论与结论

在前一章中，本文分别给出了 KNN、GMM 和 CNN 在纯净语音与混合噪声条件下的实验结果。本章在这些实验数据的基础上，从方法对比、噪声鲁棒性、信号与系统课程关联以及实验局限性等角度进行综合讨论，并给出最终结论。

### 6.1 综合结果比较

综合纯净语音和带噪语音实验结果，可以看到三种方法在小样本孤立数字识别任务中表现出明显差异。表 4 已经给出了纯净语音条件下的准确率对比：KNN 为 80.0%，GMM 与 CNN 均达到 100.0%。这说明，在无噪声条件下，MFCC 及其动态特征已经能够较好地地区分数字 0–9 的发音差异；相比简单的统计特征，保留帧级结构或利用二维特征图进行建模能够显著提升识别性能。

KNN 方法的主要优点是结构简单、实现方便、可解释性强。它将每段语音的 MFCC 帧序列压缩为均值和标准差，形成固定长度特征向量，再利用欧氏距离完成最近邻分类。这种方法适合用作基线，但其缺点也十分明显：统计池化会丢失发音过程中的时间顺序信息。例如，两段语音即使帧顺序不同，也可能具有相近的均值和标准差；而数字语音的区分往往依赖共振峰和能量分布随时间变化的动态模式。因此，KNN 在纯净语音下仍出现了若干混淆，在噪声条件下鲁棒性也最弱。

GMM 方法在传统机器学习路线中表现最好。它不再将整段语音压缩为单一统计向量，而是直接利用 39 维 MFCC +  $\Delta$  +  $\Delta^2$  帧级特征，并为每个数字类别建立概率分布模型。由于 GMM 能够对每类数字在特征空间中的分布进行建模，因此更适合处理变长语音帧序列。在本实验的小样本条件下，4 分量对角协方差 GMM 在模型复杂度和泛化能力之间取得了较好平衡：纯净语音下达到 100.0%，在 20 dB 混合噪声下也达到 91.25%，是本实验中综合表现最稳定的传统方法。

CNN 代表深度学习路线。它将 39 维动态 MFCC 特征组织为  $39 \times T$  的二维特征图，并通过卷积核自动学习局部时频模式。最终模型在纯净验证集上达到 100.0%，说明即使在训练样本较少的情况下，经过适当的数据增强和正则化，轻量级 CNN 仍能学习到有效的判别特征。在 mixed noise 测试中，CNN 从 12.5 dB 起达到 90% 以上准确率，并在 25 dB 时达到 100%。这表明噪声增强对于提升深度模型的鲁棒性具有明显作用。不过，CNN 的噪声测试采用更细的 SNR 网格，与 KNN/GMM 的 20 次重复均值实验设置并不完全一致，因此其定量优势仍需谨慎解释。

### 6.2 噪声鲁棒性分析

从图 9、图 10 和图 11 可以看出，三种方法的准确率整体均随 SNR 提升而提高。这一趋势符合信号与噪声功率关系的基本规律：当 SNR 较低时，噪声能量接近甚至超过语音信号能量，MFCC 特征中的谱包络结构被严重破坏；当 SNR 提高时，语音信号的主要频谱结构逐渐恢复，分类器能够获得更可靠的判别信息。

KNN 对噪声最敏感。其原因在于噪声会直接改变 MFCC 帧序列的整体分布，进而影响均值和标准差。由于 KNN 仅依赖欧氏距离，它无法区分由真实发音差异引起的特征变化和由噪声扰动引起的特征变化。因此，在带噪条件下，原本属于同一数字的样本可能被拉远，不同数字的样本也可能被噪声扰动到相近区域，导致分类边界不稳定。

GMM 的鲁棒性明显优于 KNN。一方面，GMM 保留了帧级特征分布，不依赖单一全局统计向量；另一方面， $\Delta$  和  $\Delta^2$  动态特征提供了频谱变化速度和加速度的信息，使模型不仅利用静态谱包络，也能利用语音随时间演化的趋势。此外，CMVN 能够减小整体能量、信道和录音条件差异对倒谱特征的影响，因此在中高 SNR 下准确率提升较为稳定。以 90% 准确率作为较高识别率标准，GMM 在本实验测试范围内的最低达标 SNR 为 20 dB。

CNN 在噪声条件下的表现受益于训练阶段的数据增强。由于训练过程中加入了白噪声、粉红噪声和 50 Hz 工频干扰，模型在训练阶段已经接触到与测试环境相近的扰动形式，因此对中等强度噪声具有更好的适应能力。与 KNN 和 GMM 依赖人工设计特征后再分类不同，CNN 可以通过卷积层自动学习局部时频结构，例如短时间内某些 MFCC 系数的连续变化模式。因此，在细粒度 mixed noise 测试中，CNN 能够在 12.5 dB 时达到 90% 准确率。不过，由于验证集仅有 20 条样本，单次测试中每错 1 条就对应 5% 的准确率变化，因此 CNN 曲线中的局部波动不应被过度解读。

### 6.3 与信号与系统课程知识的联系

本实验虽然以语音识别为应用目标，但完整流程与信号与系统课程知识密切相关。

首先，语音信号本质上是随时间变化的声压信号，经采样后成为离散时间信号。原始语音具有明显的非平稳性，因此不能仅用整体 FFT 描述其全部特征。实验中采用分帧加窗和 STFT，将非平稳语音在短时间内近似为平稳信号，从而获得时频联合表示。这体现了从时域到频域、再到时频域分析的基本思想。

其次，预加重可以视为一个一阶 FIR 高通系统，其差分方程为

$$y[n] = x[n] - 0.97x[n-1], \quad (16)$$

对应系统函数为

$$H(z) = 1 - 0.97z^{-1}. \quad (17)$$

该系统增强语音中的高频成分，使后续频谱分析更加稳定。这正是离散时间 LTI 系统在实际信号处理中应用的一个典型例子。

再次，FFT、Mel 滤波器组和 DCT 共同构成了从原始语音到 MFCC 特征的频域处理链条。FFT 将时域信号分解为不同频率成分；Mel 滤波器组相当于对频谱进行一组频域加权，模拟人耳对频率的非线性感知；DCT 则通过正交变换实现能量集中和特征去相关。这些步骤都体现了“通过变换域表示提取关键信息”的信号处理思想。

最后，噪声鲁棒性测试也与信号功率、频谱分布和滤波思想相关。白噪声、 $1/f$  噪声和 50 Hz 工频干扰分别代表不同类型的噪声源：白噪声近似覆盖全频段，粉红噪声低频能量更强，工频干扰则是典型窄带周期性干扰。不同噪声会以不同方式影响语音频谱和 MFCC 特征，因此噪声实验不仅是机器学习模型评估，也是对信号频域结构和噪声影响机制的验证。

## 6.4 实验局限性

尽管本实验完成了从信号分析、特征提取、模型训练到噪声鲁棒性测试的完整流程，但仍存在一些局限。

第一，数据集规模较小。训练集仅有 50 条语音，验证集仅有 20 条语音。对于 KNN 和 GMM 这类传统方法，小样本会限制类别分布估计的可靠性；对于 CNN 这类深度学习模型，小样本更容易导致过拟合。虽然本实验使用了数据增强和早停机制，但结果仍可能受到特定数据划分和随机噪声采样的影响。

第二，验证集说话人数量有限。本实验采用 speaker1-5 训练、speaker6-7 验证的说话人不重叠划分方式，能够初步评估跨说话人泛化能力。但由于验证说话人仅有 2 位，结果仍不足以完全代表模型在更多说话人上的表现。更严谨的实验可以采用 leave-one-speaker-out 或多折交叉验证方式。

第三，噪声测试主要考察混合噪声条件下的整体鲁棒性，而没有分别分析单一噪声源的影响。白噪声、粉红噪声和 50 Hz 工频干扰对语音特征的破坏机制并不相同。若要进一步理解模型对不同噪声的敏感性，应分别绘制三类噪声下的准确率-SNR 曲线，并比较各模型在不同噪声类型下的性能差异。

第四，不同方法的噪声测试设置并不完全一致。KNN 与 GMM 采用 7 个 SNR 等级、每个等级 20 次重复实验；CNN 则采用更细的 SNR 网格进行 mixed noise 测试。因此，本报告主要比较三者的变化趋势和最低可用 SNR，而不将 CNN 与 KNN/GMM 的曲线作严格统计显著性比较。

## 6.5 结论

本实验完成了基于信号处理的孤立数字语音识别系统设计。实验首先对语音信号进行了时域波形、FFT 幅度谱和 STFT 语谱图分析；随后实现了预加重、分帧加窗、Mel 滤波、对数压缩、DCT 和动态差分特征提取，得到 13 维 MFCC 及 39 维 MFCC +  $\Delta$  +  $\Delta^2$  特征；最后分别采用 KNN、GMM 和 CNN 进行数字分类，并在混合噪声下评估鲁棒性。

实验结果表明，MFCC 及动态特征能够有效刻画孤立数字语音的谱包络和时间变化信息。在纯净语音条件下，GMM 和 CNN 均达到 100.0% 验证准确率，KNN 达到 80.0%。在混合噪声条件下，KNN 鲁棒性较弱，在测试范围内未达到 90% 准确率；GMM 在 20 dB 时达到 91.25%，是综合表现最稳定的传统方法；CNN 借助噪声增强和卷积特征学习，在 mixed noise 细粒度测试中从 12.5 dB 起达到 90% 以上准确率。

总体而言，本实验验证了经典信号处理特征与机器学习方法在小样本语音识别任务中的有效性。传统方法具有结构清晰、可解释性强的优势；深度学习方法具有更强的特征学习能力，但对数据规模和训练策略更加敏感。对于本任务而言，动态 MFCC 特征、合理的归一化处理以及面向噪声的训练或建模策略，是提升识别准确率和噪声鲁棒性的关键。

## 七、团队分工

本实验由四名组员协作完成，整体工作包括数据预处理、语音信号分析、特征提取、传统机器学习模型、深度学习模型、噪声鲁棒性测试、结果可视化、报告撰写和展示材料整理。各成员在完成各自模块的基础上，也对整体实验流程、结果分析和报告修改进行了讨论与协作。

表 7: 团队成员分工

| 成员  | 主要工作                                                                                                        |
|-----|-------------------------------------------------------------------------------------------------------------|
| 于沛龙 | 负责传统方法基线流程搭建，包括语音预处理、端点检测、MFCC 特征提取、KNN 基线模型实现与测试；参与噪声鲁棒性实验、结果图表整理、PPT 制作与实验报告统稿。                           |
| 景序  | 负责传统方法优化部分，设计并实现基于 MFCC + $\Delta$ + $\Delta^2$ 帧级特征的 GMM 序列模型；完成 GMM 纯净语音测试、噪声鲁棒性重复实验、准确率-SNR 曲线绘制及相关结果分析。 |
| 封宇凡 | 负责深度学习方法部分，设计并训练 CNN 模型；完成 MFCC 动态特征图输入构建、网络结构设计、模型训练参数调优、纯净语音测试和混合噪声细粒度 SNR 测试。                            |
| 孟德轩 | 参与数据处理、实验结果核对、图表整理和报告材料撰写；协助完成实验流程梳理、不同方法结果对照、报告格式检查以及展示内容整理。                                               |

在协作过程中，小组首先确定整体技术路线：以 MFCC 为核心声学特征，分别构建 KNN、GMM 和 CNN 三种识别方法，并统一使用 speaker1-5 作为训练集、speaker6-7 作为验证集。随后，各成员分别完成对应模型的实现与测试，并将输出结果统一整理为混淆矩阵、准确率表格和准确率-SNR 曲线。最后，小组共同对实验结果进行比较分析，讨论不同方法在小样本条件和混合噪声条件下的优劣，完成最终实验报告和课程展示材料。

## 参考文献

- [1] OPPENHEIM A V, WILLSKY A S, NAWAB S H. Signals and Systems[M]. Prentice Hall, 1997.
- [2] 胡光锐, 徐昌庆. 信号与系统[M]. 第 2 版. 上海交通大学出版社, 2010.
- [3] 知乎专栏. 混淆矩阵详解[Z]. <https://zhuanlan.zhihu.com/p/681998308>. 课程任务书推荐参考资料.