

基于信号处理的孤立数字语音识别实验报告

于沛龙 景序 封宇凡 孟德轩

2026年5月

摘要

本实验面向数字 0-9 的孤立词语音识别任务，基于 7 位说话人共 70 段语音（训练集 speaker1-5 共 50 条，验证集 speaker6-7 共 20 条），完成了语音信号分析、MFCC 特征提取、分类识别和噪声鲁棒性测试。在信号处理方面，对语音进行端点检测、预加重、分帧加窗和短时傅里叶分析，提取 13 维 MFCC 及其一阶、二阶动态差分特征（共 39 维）。在分类方面，分别采用基于 26 维统计特征的 KNN 基线、基于 39 维帧级序列特征的 GMM 模型以及基于 MFCC 动态特征图的卷积神经网络（TinyKeywordCNN）进行数字分类。实验结果表明，纯净语音条件下 GMM 达到最高识别准确率，MFCC 及动态特征能够有效描述语音谱包络和时序变化；在混合噪声（白噪声、1/f 粉红噪声与 50 Hz 工频干扰）条件下，各模型识别性能随信噪比降低而下降。实验验证了信号处理方法在语音识别中的有效性，同时也揭示了小样本数据集下不同方法的优劣与局限。

关键词：孤立词语音识别；MFCC；KNN；GMM；CNN；噪声鲁棒性；信号与系统

目录

一、 实验目的与数据集	3
1.1 实验背景与目的	3
1.2 数据集	3
1.3 实验评价设置	4
二、 语音信号分析	4
2.1 时域波形	4
2.2 频域分析	4
2.3 短时傅里叶变换与语谱图	5
三、 特征提取	5
3.1 预加重	6
3.2 分帧、加窗与短时傅里叶变换	6
3.3 梅尔滤波器组	6
3.4 对数压缩与离散余弦变换	7
3.5 动态特征	7
3.6 与信号与系统课程的关联	8
四、 识别方法	9
4.1 MFCC 统计特征与 KNN 基线	9
4.2 MFCC 序列特征与 GMM 模型	10
4.3 MFCC 动态特征图与 TinyKeywordCNN	11
4.4 三种方法的对比	12

一、实验目的与数据集

1.1 实验背景与目的

孤立词语音识别是语音识别领域的基础任务之一，其目标是将说话人发出的单个词语（如数字、命令词）映射为对应的文本标签。本实验面向数字 0-9 的孤立词语音识别任务，完成从语音信号分析、特征提取、模型训练到噪声鲁棒性评估的完整流程。

从信号与系统的视角看，语音信号是典型的离散时间非平稳信号，整个识别流程涉及多个课程核心概念：

- 预加重等效于一阶 FIR 高通滤波器，用于补偿语音高频部分的衰减；
- 分帧加窗利用短时平稳假设，将非平稳语音信号转化为准平稳帧序列；
- 短时傅里叶变换（STFT）实现信号的时频域联合分析；
- 梅尔滤波器组模拟人耳的非线性频率感知特性，体现了频域加权的思想；
- 离散余弦变换（DCT）用于特征去相关与压缩，是正交变换的典型应用。

通过对比不同特征表示和分类模型在纯净及含噪条件下的识别性能，本实验旨在加深对信号处理技术在语音识别中应用的理解，并探索传统方法与深度学习方法在小样本数据集下的优劣。

1.2 数据集

实验数据集包含 7 位说话人，每人分别朗读数字 0-9 一遍，共计 70 段语音。所有语音以 16 kHz 采样率、单声道格式存储。原始语音通过基于短时能量的端点检测算法自动切分为独立发音片段。

为保证训练集与验证集之间无说话人重叠，数据集按照说话人身份进行划分，如表 1 所示。

表 1: 数据集划分

划分	说话人	样本数
训练集	speaker 1-5	50
验证集	speaker 6-7	20

训练集每数字包含 5 个不同说话人的发音样本，验证集每数字包含 2 个不同于训练说话人的发音样本。说话人不重叠的划分方式能够更真实地反映模型的泛化能力，避免模型仅记忆特定说话人的声纹特征。

1.3 实验评价设置

在纯净语音条件下，以识别准确率和混淆矩阵作为主要评价指标，用以评估各模型对不同数字的区分能力。

在噪声鲁棒性测试中，向验证集语音叠加混合噪声，噪声由以下三种成分等功率混合并经 RMS 归一化得到：

- 高斯白噪声；
- 1/f 粉红噪声（频域法生成）；
- 50 Hz 工频干扰（正弦波）。

测试设置 7 个信噪比（SNR）等级：-10 dB、-5 dB、0 dB、5 dB、10 dB、15 dB、20 dB，覆盖从强噪声到弱噪声的完整范围。通过考察各模型在不同 SNR 下的识别准确率变化趋势，评估其噪声鲁棒性。

二、 语音信号分析

2.1 时域波形

语音信号在时域中表现为幅度随时间变化的离散序列。时域波形可以反映语音的能量包络、发音起止位置以及静音段分布，因此可用于端点检测。




图 1: 语音信号时域波形

2.2 频域分析

对离散语音信号作快速傅里叶变换（FFT），可得到其整体频率能量分布。离散傅里叶变换定义为

$$X[k] = \sum_{n=0}^{N-1} x[n]e^{-j2\pi kn/N}. \quad (1)$$

频谱图能够反映语音信号的主要频率成分和共振峰分布，但由于语音信号是典型非平稳信号，整体 FFT 无法表示频谱随时间的动态变化。




图 2: 语音信号 FFT 幅度谱

2.3 短时傅里叶变换与语谱图

为分析语音信号的时变频谱特性，实验采用短时傅里叶变换（STFT）。其基本思想是对信号进行分帧和加窗，在每一短时帧内近似认为信号平稳，再分别进行傅里叶变换：

$$X(m, k) = \sum_{n=0}^{N-1} x[n]w[n-m]e^{-j2\pi kn/N}. \quad (2)$$

本实验采用 25 ms Hamming 窗和 10 ms 帧移。语谱图横轴为时间，纵轴为频率，颜色表示能量强弱，可以同时展示语音的时间、频率和能量变化。




图 3: 语音信号 STFT 语谱图

三、 特征提取

语音信号经过预处理和短时分析后，需要进一步提取能够表征不同数字之间声学差异的特征。梅尔频率倒谱系数（Mel-Frequency Cepstral Coefficients, MFCC）是语音识别中最广泛应用的特征之一，其设计模拟了人耳对声音的非线性感知特性。本节详细介绍 MFCC 特征提取的完整流程，包括预加重、分帧加窗、FFT 与功率谱、梅尔滤波、对数压缩与离散余弦变换，以及动态特征的构建。

3.1 预加重

语音信号在唇辐射和空气传输过程中，高频分量会自然衰减。为补偿这一效应，首先对离散语音信号 $x[n]$ 进行预加重（pre-emphasis），即通过一阶 FIR 高通滤波器：

$$y[n] = x[n] - \alpha x[n-1], \quad (3)$$

其中预加重系数 $\alpha = 0.97$ 。该滤波器的作用是增强信号的高频成分，使频谱在高频段更加平坦，有利于后续的频谱分析。从信号与系统的角度看，该系统的传递函数为 $H(z) = 1 - \alpha z^{-1}$ ，是一个简单的一阶高通 FIR 滤波器。

3.2 分帧、加窗与短时傅里叶变换

语音信号是典型的非平稳信号，其统计特性随时间变化。但在较短的时段（约 20–30 ms）内，发音器官的运动相对缓慢，信号可近似视为平稳。基于这一短时平稳假设，对预加重后的信号进行分帧处理：采用窗长为 25 ms 的 Hamming 窗，帧移为 10 ms。在 16 kHz 采样率下，窗长对应 $N = 400$ 个采样点，帧移对应 160 个采样点。

Hamming 窗的时域表达式为

$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right), \quad 0 \leq n \leq N-1. \quad (4)$$

加窗可以减小帧边界处的不连续性，抑制频谱泄漏。

对每一帧加窗后的信号进行 K 点 FFT，得到短时幅度谱 $|X(m, k)|$ ，进而计算功率谱 $|X(m, k)|^2$ 。关于 STFT 的详细讨论见语音信号分析一节。

3.3 梅尔滤波器组

人耳对声音频率的感知是非线性的：在低频区域，人耳能够分辨较细微的频率差异；而在高频区域，频率分辨率则相对较低。梅尔（Mel）尺度正是为了模拟这一感知特性而提出的一种频率映射，其与物理频率 f （Hz）的近似关系为

$$\text{Mel}(f) = 2595 \log_{10}\left(1 + \frac{f}{700}\right). \quad (5)$$

在梅尔尺度上等间距地放置一组三角滤波器，再映射回线性频率轴，即构成梅尔滤波器组。梅尔滤波器在低频段分布密集、在高频段分布稀疏，体现了人耳的非线性频率分辨率。

本实验采用 40 个三角梅尔滤波器，频率范围为 20 Hz 至 7600 Hz（对应 16 kHz 采样的奈奎斯特频率以下）。每一帧的功率谱通过梅尔滤波器组后，得到 40 维的对数梅尔能量。

3.4 对数压缩与离散余弦变换

将梅尔滤波器组的输出取对数，一方面模拟人耳对响度的对数感知特性，另一方面压缩动态范围，使特征对输入能量的绝对大小不敏感：

$$S(m, l) = \log \left(\sum_{k=0}^{K-1} |X(m, k)|^2 \cdot H_l[k] \right), \quad (6)$$

其中 $H_l[k]$ 为第 l 个梅尔滤波器的频率响应， $l = 0, 1, \dots, L-1$ ， $L = 40$ 。

对数梅尔能量各维度之间存在较强的相关性。为降低特征维度并去除相关性，对 $S(m, l)$ 沿滤波器轴进行离散余弦变换（DCT）：

$$c(m, i) = \sum_{l=0}^{L-1} S(m, l) \cos \left[\frac{\pi i}{L} \left(l + \frac{1}{2} \right) \right], \quad i = 0, 1, \dots, N_{\text{mfcc}} - 1. \quad (7)$$

DCT 是一种正交变换，能够将能量集中到少数低阶系数上，同时使各阶倒谱系数近似不相关。保留前 $N_{\text{mfcc}} = 13$ 个 DCT 系数，即为该帧的 MFCC 特征。

值得注意的是，第 0 阶系数 $c(m, 0)$ （常记为 C0）主要反映该帧的整体能量，数值通常远大于其余系数。在后续特征可视化中，为避免 C0 掩盖其他倒谱系数的细节结构，13 维 MFCC 图在绘制时省略 C0，仅显示 C1–C12。




图 4: 13 维 MFCC 特征图（可视化时省略 C0，仅显示 C1–C12）。横轴为帧序号，纵轴为 MFCC 系数阶数，颜色表示系数值的大小。

3.5 动态特征

静态 MFCC 仅反映当前帧的频谱包络信息，无法刻画语音信号随时间变化的动态特性。为此，在 13 维静态 MFCC 的基础上，分别计算一阶差分（Delta, Δ ）和二

阶差分 (Delta-Delta, Δ^2):

$$\Delta_t = \frac{\sum_{n=1}^{N_d} n (c_{t+n} - c_{t-n})}{2 \sum_{n=1}^{N_d} n^2}, \quad (8)$$

其中 c_t 为第 t 帧的 MFCC 向量, N_d 为差分窗口半径 (本实验取 $N_d = 2$)。 Δ^2 以同样的方式在 Δ 序列上计算得到。

最终, 每一帧的特征向量由 13 维静态 MFCC、13 维 Δ 和 13 维 Δ^2 拼接而成, 共计 39 维帧级特征。动态特征的引入使模型能够同时利用频谱包络的静态信息和帧间变化的动态信息, 从而更好地建模语音的时序演变规律。




图 5: 39 维 MFCC + Δ + Δ^2 特征图。上段为 13 维静态 MFCC (含 C0), 中段为 13 维 Δ , 下段为 13 维 Δ^2 。横轴为帧序号, 纵轴为系数阶数。

图 4 和图 5 分别展示了同一语音段在两种特征表示下的可视化结果。13 维特征图 (图 4) 聚焦于静态频谱包络的时变模式, 不同数字的 MFCC 在特定系数阶数上呈现出差异化的能量分布; 39 维特征图 (图 5) 则进一步整合了动态信息, Δ 和 Δ^2 分量反映了频谱变化的速率与加速度, 为后续的分类模型提供了更丰富的时序判别依据。

3.6 与信号与系统课程的关联

MFCC 特征提取流程与信号与系统课程的知识体系紧密相关。预加重对应一阶 FIR 滤波器的设计与频率响应分析; 分帧加窗涉及信号截断与频谱泄漏问题, 是离散时间信号处理的重要内容; FFT 和功率谱估计是频域分析的核心工具, 在语音信号分析一节中已有详细讨论; 梅尔滤波器组体现了频域加权的思想, 本质上是对功率谱的频域滤波; 对数运算实现动态范围压缩, 与信号的非线性变换相关; DCT 作为正交变换, 具有能量集中和去相关的优良性质, 是信号表示理论中的典型方法。这些信号处理技术的有机结合, 构成了从原始语音波形到紧凑声学特征表示的关键桥梁。

四、 识别方法

在完成语音信号分析和 MFCC 特征提取之后，需要设计分类模型将特征向量映射为数字标签 0–9。本实验采用三种不同类型的分类方法：基于统计特征聚合的 K 近邻（KNN）基线方法、基于帧级序列概率建模的高斯混合模型（GMM），以及基于卷积神经网络（CNN）的深度学习方法。三种方法在输入特征形式、建模策略和模型复杂度上各有不同，构成了从简单到复杂的对比实验。

4.1 MFCC 统计特征与 KNN 基线

KNN 是一种简单直观的非参数分类方法，适合作为小样本语音识别任务的基线。为使变长帧序列能够输入基于固定长度向量的 KNN 分类器，本实验对每段语音的 13 维 MFCC 帧级特征沿时间轴分别计算均值和标准差，拼接为 26 维固定长度特征向量：

$$\mathbf{f} = [\boldsymbol{\mu}, \boldsymbol{\sigma}], \quad \boldsymbol{\mu} = \frac{1}{T} \sum_{t=1}^T \mathbf{c}_t, \quad \boldsymbol{\sigma} = \sqrt{\frac{1}{T} \sum_{t=1}^T (\mathbf{c}_t - \boldsymbol{\mu})^2}, \quad (9)$$

其中 $\mathbf{c}_t \in \mathbb{R}^{13}$ 为第 t 帧的 MFCC 向量， T 为该语音段的总帧数。

在分类之前，使用 StandardScaler 对特征进行标准化，使各维特征具有零均值和单位方差。分类器采用 $k = 1$ 的最近邻分类器，距离度量为欧氏距离：

$$\hat{y} = \arg \min_{c \in \{0, \dots, 9\}} \|\mathbf{f} - \mathbf{f}_c^{\text{train}}\|_2. \quad (10)$$

该方法的优点在于简单、可解释，且无需训练过程，非常适合小样本场景。然而，均值与标准差的统计池化操作丢弃了帧之间的时序顺序信息——两段发音顺序完全不同的语音可能具有相近的统计量，从而导致误判。此外，尝试将 39 维动态特征（MFCC + Δ + Δ^2 ）也以同样方式池化后输入 KNN 时，验证准确率反而下降，推测原因是高维特征下统计池化加剧了信息损失，欧氏距离的判别能力也随之减弱。




图 6: KNN 纯净语音混淆矩阵（准确率 80.0%，16/20）。主要混淆为 $0 \rightarrow 7$ 、 $2 \rightarrow 8$ 、 $4 \rightarrow 3$ 、 $6 \rightarrow 9$ ，表明统计特征的判别力不足以区分部分发音相近的数字对。

4.2 MFCC 序列特征与 GMM 模型

GMM 通过对每一类数字的概率密度进行参数化建模，能够直接处理变长帧序列，避免了将语音“压缩”为固定统计量的过程。本实验为每个数字类别 $c \in \{0, \dots, 9\}$ 分别训练一个 GMM，模型参数为 $\lambda_c = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^K$ 。

输入特征为 39 维帧级特征 $\mathbf{x}_t \in \mathbb{R}^{39}$ （13 维 MFCC + 13 维 Δ + 13 维 Δ^2 ）。在训练前，对特征进行倒谱均值方差归一化（Cepstral Mean and Variance Normalization, CMVN），以减小信道差异和录音环境的影响。每个 GMM 包含 $K = 4$ 个高斯分量，协方差矩阵约束为对角形式，以在参数量和建模能力之间取得平衡。模型参数通过期望最大化（EM）算法从训练样本中估计。

对于一段包含 T 帧的语音 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_T\}$ ，其属于类别 c 的对数似然为

$$\log p(\mathbf{X} | \lambda_c) = \sum_{t=1}^T \log \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_t | \mu_k, \Sigma_k). \quad (11)$$

最终判决为对数似然最大的类别：

$$\hat{y} = \arg \max_c \log p(\mathbf{X} | \lambda_c). \quad (12)$$

GMM 方法的主要优势在于：保留完整的帧序列信息，不进行统计池化，能够更充分地利用 MFCC 动态特征的时序变化特性；对角协方差假设在参数量可控的前提下，仍能有效建模各类数字在特征空间中的分布。在小样本条件下，GMM 的表现尤

为突出。




图 7: GMM 纯净语音混淆矩阵（准确率 100.0%，20/20）。20 条验证样本全部识别正确，表明 GMM 结合 39 维动态特征在小样本场景下具有优异的分类性能。

4.3 MFCC 动态特征图与 TinyKeywordCNN

为进一步探索深度学习方法在小样本语音识别任务中的潜力，本实验采用了一个轻量级卷积神经网络 TinyKeywordCNN。与 KNN 和 GMM 不同，CNN 将 39 维 MFCC 帧级特征排列为 $39 \times T$ 的二维特征图（类似于单通道图像），通过卷积操作自动学习局部时频模式。

TinyKeywordCNN 的总体参数量为 102,522，结构如表 2 所示。网络包含 4 个卷积块，通道数从 1 逐步扩展至 128，每个卷积块由 Conv2d（ 3×3 卷积核）、BatchNorm2d 和 ReLU 激活函数组成。前三块后各接一个 2×2 最大池化层以逐步降低特征图尺寸；第四块后使用自适应平均池化将特征图统一压缩至 2×2 ，随后经 Flatten 展开为 512 维向量，再通过 Dropout（ $p = 0.3$ ）和全连接层输出 10 类对数概率。

表 2: TinyKeywordCNN 网络结构

层	输出尺寸	参数量
ConvBlock (1 $\rightarrow$ 16) + MaxPool	$16 \times 19 \times T/2$	144
ConvBlock (16 $\rightarrow$ 32) + MaxPool	$32 \times 9 \times T/4$	4,608
ConvBlock (32 $\rightarrow$ 64) + MaxPool	$64 \times 4 \times T/8$	18,432
ConvBlock (64 $\rightarrow$ 128)	$128 \times 4 \times T/8$	73,728
AdaptiveAvgPool2d + Flatten	512	0
Dropout + Linear(512, 10)	10	5,130
总计		102,522

训练采用 AdamW 优化器，学习率为 0.001，权重衰减为 0.0001，batch size 为 16，最大训练轮次为 120。为缓解小样本带来的过拟合风险，训练中加入了数据增强策略：以 0.3 的概率向训练样本添加随机噪声段、随机增益扰动 (± 3 dB) 和随机时间平移 (± 120 ms)。采用早停机制，patience 设置为 20 个轮次（来源：train_summary.json 中的实际训练配置），最佳验证准确率出现在第 37 轮。




图 8: CNN 纯净语音混淆矩阵（准确率 95.0%，19/20）。仅出现 1 个错误：数字 2 被误判为数字 6。

CNN 方法的主要优势在于能够通过卷积核自动学习 MFCC 特征图中的局部时频模式，不需要人工定义统计量或概率分布假设。然而，深度学习模型通常依赖较大规模的数据集以充分发挥其表示能力；在本实验仅 50 条训练样本的条件下，CNN 的泛化表现受到一定限制。

4.4 三种方法的对比

表 3 从输入特征、建模方式和主要特点三个维度对三种方法进行了总结。

表 3: 三种识别方法的对比

方法	输入特征	建模方式	主要特点
KNN	26 维统计特征 (13 维 MFCC 均值+标准差)	1-NN, 欧氏距离	简单可解释，无需训练； 但统计池化丢失时序信息
GMM	39 维帧级序列特征 (MFCC + Δ + Δ^2)	4 分量对角协方差 GMM, 最大对数似然判决	保留变长帧序列，适合小样本； 概率建模稳定，时序建模能力强
CNN	$39 \times T$ 特征图 (MFCC + Δ + Δ^2)	4 层卷积网络, 102k 参数, 数据增强 + 早停	自动学习局部时频模式； 表示能力强，但对数据量更敏感

三种方法从不同角度解决了”如何利用 MFCC 特征进行数字分类”这一问题：KNN 最为简单，以统计聚合换取固定维度输入； GMM 在保留序列信息和控制模型复杂度之间取得良好平衡，尤其适合本实验的小样本场景； CNN 具有最强的表示学习能力，但在极小数据集上需要依赖数据增强和正则化手段来防止过拟合。三者 in 纯净语音条件下的准确率比较和噪声鲁棒性分析将在下一章详细讨论。