

基于信号处理的孤立数字语音识别实验报告

于沛龙 景序 封宇凡 孟德轩

2026 年 5 月

摘要

关键词：孤立词语音识别；MFCC；KNN；GMM；CNN；噪声鲁棒性；信号与系统

目录

一、 语音信号分析	3
1.1 时域波形	3
1.2 频域分析	3
1.3 短时傅里叶变换与语谱图	4
二、 分类方法	4
2.1 MFCC 统计特征 + KNN (Baseline)	4
2.2 MFCC 动态序列特征 + GMM	4
2.2.1 39 维动态特征提取	5
2.2.2 倒谱均值方差归一化 (CMVN)	5
2.2.3 GMM 分类器	5
2.2.4 与 Baseline 方法的对比	6
三、 实验结果与噪声鲁棒性分析	7
3.1 MFCC 统计特征 + KNN 结果	7
3.2 MFCC 动态序列特征 + GMM 结果	7
3.2.1 纯净语音条件下的识别结果	7
3.2.2 噪声鲁棒性测试	7
3.3 CNN 方法结果	9
四、 讨论与结论	9
4.1 各改进对识别性能的贡献分析	9
4.1.1 动态特征的贡献	9
4.1.2 CMVN 的贡献	9
4.1.3 GMM 概率建模的优势	9
4.2 噪声鲁棒性分析	10
4.3 与 Baseline 方法的性能对比	10
4.4 局限性与改进方向	10

本实验面向数字 0-9 的孤立词语音识别任务，完成了从数据预处理、信号分析、特征提取、模型训练到噪声鲁棒性测试的完整流程。实验首先对语音信号进行端点检测、预加重、分帧加窗和短时傅里叶分析，并提取梅尔频率倒谱系数（MFCC）及其动态特征。随后，分别采用 MFCC 统计特征结合 KNN、MFCC 序列特征结合 GMM，以及基于 MFCC 动态特征图的 CNN 模型进行数字分类。实验结果表明，在纯净语音条件下，GMM 方法取得了较高识别准确率；在混合噪声条件下，识别性能随信噪比降低而下降。通过对时域、频域、时频域特征和不同模型性能的对比分析，实验验证了信号处理方法在语音识别任务中的有效性，并讨论了小样本数据集下不同方法的优劣与局限。

一、 语音信号分析

1.1 时域波形

语音信号在时域中表现为幅度随时间变化的离散序列。时域波形可以反映语音的能量包络、发音起止位置以及静音段分布，因此可用于端点检测。




图 1: 语音信号时域波形

1.2 频域分析

对离散语音信号作快速傅里叶变换（FFT），可得到其整体频率能量分布。离散傅里叶变换定义为

$$X[k] = \sum_{n=0}^{N-1} x[n]e^{-j2\pi kn/N}. \quad (1)$$

频谱图能够反映语音信号的主要频率成分和共振峰分布，但由于语音信号是典型非平稳信号，整体 FFT 无法表示频谱随时间的动态变化。




图 2: 语音信号 FFT 幅度谱

1.3 短时傅里叶变换与语谱图

为分析语音信号的时变频谱特性，实验采用短时傅里叶变换（STFT）。其基本思想是对信号进行分帧和加窗，在每一短时帧内近似认为信号平稳，再分别进行傅里叶变换：

$$X(m, k) = \sum_{n=0}^{N-1} x[n]w[n-m]e^{-j2\pi kn/N}. \quad (2)$$

本实验采用 25 ms Hamming 窗和 10 ms 帧移。语谱图横轴为时间，纵轴为频率，颜色表示能量强弱，可以同时展示语音的时间、频率和能量变化。




图 3: 语音信号 STFT 语谱图

二、 分类方法

2.1 MFCC 统计特征 + KNN (Baseline)

2.2 MFCC 动态序列特征 + GMM

针对 baseline 方法中“均值/方差”统计压缩丢失时序信息的问题，本方法保留了语音的帧级时序结构，将每段语音建模为变长特征序列 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T\}$ ，其中 $\mathbf{x}_t \in \mathbb{R}^{39}$ ，

T 为帧数。在此基础上, 采用高斯混合模型 (Gaussian Mixture Model, GMM) 作为分类器, 从概率密度建模的角度直接处理变长序列。

2.2.1 39 维动态特征提取

仅使用 13 维静态 MFCC 只能描述当前帧的瞬时频谱包络, 无法刻画语音信号的动态变化趋势。为此, 在静态 MFCC 的基础上引入一阶差分 (Δ) 和二阶差分 (Δ^2) 系数。

一阶差分 Δ 通过线性回归计算第 t 帧附近 N 帧窗口内的斜率, 近似该帧处特征的一阶时间导数:

$$\Delta_t = \frac{\sum_{i=1}^N i \cdot (\mathbf{c}_{t+i} - \mathbf{c}_{t-i})}{2 \sum_{i=1}^N i^2} \quad (3)$$

其中 $\mathbf{c}_t$ 为第 t 帧的 13 维 MFCC 向量, $N = 2$ 为上下文窗口宽度。该公式对窗口内每条差分给予与距离成正比的权重, 距离越远的帧对斜率估计贡献越大。

二阶差分 Δ^2 将一阶差分 Δ 再次通过同一回归公式计算得到, 近似二阶时间导数, 反映频谱变化的“加速度”。最终将三者沿特征维度拼接:

$$\mathbf{x}_t = [\text{MFCC}_t \mid \Delta_t \mid \Delta_t^2] \in \mathbb{R}^{39} \quad (4)$$

其中 MFCC_t 为 13 维静态系数, Δ_t 为 13 维一阶差分, Δ_t^2 为 13 维二阶差分。39 维特征同时编码了当前帧的频谱形状、变化速度和变化加速度, 为后续 GMM 提供了更丰富的声学判别信息。

2.2.2 倒谱均值方差归一化 (CMVN)

不同说话人或不同录音条件下的信道差异会使 MFCC 分布发生整体偏移和尺度变化。为降低此类变异对分类的影响, 在提取 39 维特征后, 对每句语音逐维度进行基于句子的均值方差归一化 (Cepstral Mean and Variance Normalization, CMVN):

$$\hat{\mathbf{x}}_t^{(d)} = \frac{\mathbf{x}_t^{(d)} - \mu^{(d)}}{\sigma^{(d)} + \varepsilon}, \quad \mu^{(d)} = \frac{1}{T} \sum_{t=1}^T \mathbf{x}_t^{(d)}, \quad \sigma^{(d)} = \sqrt{\frac{1}{T} \sum_{t=1}^T (\mathbf{x}_t^{(d)} - \mu^{(d)})^2} \quad (5)$$

其中 $d = 1, \dots, 39$ 为特征维索引, $\varepsilon = 10^{-8}$ 防止除零。CMVN 使每维特征在句内均值零、方差为一, 有助于消除信道卷积噪声的线性滤波效应, 并减小不同说话人之间的特征分布差异。

2.2.3 GMM 分类器

高斯混合模型将数据分布建模为 K 个高斯分量的加权和。对于数字类别 $c \in \{0, 1, \dots, 9\}$, 独立训练一个 GMM, 其概率密度函数为:

$$p(\mathbf{x} | \lambda_c) = \sum_{k=1}^K w_{c,k} \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_{c,k}, \boldsymbol{\Sigma}_{c,k}) \quad (6)$$

其中 $w_{c,k}$ 为第 k 个分量的混合权重 ($\sum_k w_{c,k} = 1$), $\boldsymbol{\mu}_{c,k}$ 为均值向量, $\boldsymbol{\Sigma}_{c,k}$ 为协方差矩阵。本实验设定 $K = 4$ 个高斯分量, 协方差类型为对角阵 (**diag**), 兼顾模型容量与参数估计稳定性。

训练阶段, 对每个数字类别 c , 将该类所有训练样本的全部帧拼接为训练集 $X_c = \{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(M_c)}\}$, 通过期望最大化 (EM) 算法迭代估计 GMM 参数 $\lambda_c = \{w_{c,k}, \boldsymbol{\mu}_{c,k}, \boldsymbol{\Sigma}_{c,k}\}_{k=1}^K$ 。

预测阶段, 对于测试样本的特征序列 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_T\}$, 假设各帧独立同分布, 计算该序列在每个类 GMM 下的平均对数似然:

$$\log p(X | \lambda_c) = \frac{1}{T} \sum_{t=1}^T \log \sum_{k=1}^K w_{c,k} \mathcal{N}(\mathbf{x}_t | \boldsymbol{\mu}_{c,k}, \boldsymbol{\Sigma}_{c,k}) \quad (7)$$

取对数似然最大的类别作为预测结果: $\hat{y} = \arg \max_c \log p(X | \lambda_c)$ 。与 KNN 仅比较样本间距离不同, GMM 从概率生成模型的角度显式建模每类语音的帧级特征分布, 能够更充分地利用时序特征的统计信息。

2.2.4 与 Baseline 方法的对比

表 1 总结了 Advanced GMM 方法与 baseline KNN 方法的主要区别。

表 1: Baseline KNN 与 Advanced GMM 方法对比

维度	Baseline KNN	Advanced GMM
特征维度	13 维 MFCC	39 维 (MFCC + Δ + Δ^2)
时序处理	均值/方差压缩为 26 维定长向量, 丢弃时序	保留全部帧序列 ($T, 39$)
归一化	StandardScaler (全局)	CMVN (逐句均值方差归一化)
分类器	1-NN (基于欧氏距离)	GMM ($K = 4$, 对角协方差, 对数似然评分)
决策依据	最近邻样本标签	各类别概率密度建模

三、实验结果与噪声鲁棒性分析

3.1 MFCC 统计特征 + KNN 结果

3.2 MFCC 动态序列特征 + GMM 结果

3.2.1 纯净语音条件下的识别结果

在纯净语音(clean)条件下,使用 speaker1–speaker5(共 50 个样本)训练,speaker6–speaker7(共 20 个样本)验证,Advanced GMM 方法取得了 **100%** 的识别准确率,即 20 个验证样本全部正确分类。




图 4: Advanced GMM 在纯净语音条件下的混淆矩阵

图 4 给出了对应的混淆矩阵。可以看出,所有数字类别的 F_1 分数、精确率和召回率均为 1.0000,验证集上未出现任何误识别。与 baseline KNN 在同样条件下的 80% 准确率相比,Advanced GMM 的识别性能有显著提升,说明保留时序信息和使用概率生成模型对数字语音识别是有效的。

3.2.2 噪声鲁棒性测试

为评估方法对噪声的鲁棒性,使用混合噪声(白噪声 + 粉红噪声 + 50 Hz 工频干扰)在 -10 dB 至 20 dB 七个 SNR 等级下进行重复加噪测试。每个 SNR 等级重复 20 次,每次从噪声文件中随机截取片段与验证集语音混合,以排除单次噪声抽样的偶然性。最终统计各 SNR 下的平均准确率与标准差。

表 2: Advanced GMM 在不同 SNR 下的噪声鲁棒性结果（20 次重复）

SNR (dB)	平均准确率	标准差
-10	0.1000	1.39×10^{-17}
-5	0.1575	0.0426
0	0.3800	0.0731
5	0.5575	0.0729
10	0.7250	0.0433
15	0.8525	0.0460
20	0.9125	0.0311




图 5: Advanced GMM 在不同 SNR 下的准确率变化曲线（误差线： $\pm 1\sigma$ ）

表 2 和图 5 共同展示了噪声鲁棒性测试结果。可以看出：

- (1) 随 SNR 从 -10 dB 上升至 20 dB ，平均准确率从 0.1000 单调上升至 0.9125 ，呈现清晰的 SNR-性能正相关趋势；
- (2) 在 20 dB 高 SNR 条件下，平均准确率达到 0.9125 ，已接近纯净条件下的 1.0000 ，说明该方法对低强度噪声具有一定容忍度；
- (3) 在 0 dB 及以上 SNR 条件下，准确率恢复至 0.38 以上且稳定提升，而在 -5 dB 和 -10 dB 极端低 SNR 下准确率接近随机水平 (0.10)；
- (4) 标准差随 SNR 提升整体呈下降趋势，表明高 SNR 下结果更加稳定。

3.3 CNN 方法结果

四、 讨论与结论

4.1 各改进对识别性能的贡献分析

4.1.1 动态特征的贡献

从 13 维静态 MFCC 扩展到 39 维动态特征 ($\text{MFCC} + \Delta + \Delta^2$) 是 Advanced GMM 方法性能提升的关键因素之一。静态 MFCC 仅反映当前帧的瞬时频谱包络，而 Δ 和 Δ^2 分别编码了频谱随时间变化的速度和加速度。这些动态特征在语音识别中尤为重要，因为不同数字的发音在共振峰过渡、能量上升/衰减速率等方面存在显著差异。例如，数字“6”和“9”在静态 MFCC 空间中可能较为接近，但它们的频谱变化轨迹不同——“6”的发音通常以低频能量逐步衰减为特征，而“9”则涉及更复杂的共振峰运动——这些差异在动态特征空间中更容易被区分。

4.1.2 CMVN 的贡献

CMVN（倒谱均值方差归一化）在句子级别将每维特征归零均值、单位方差，有效抑制了信道卷积噪声和说话人差异带来的线性频谱畸变。与 baseline 中使用的全局 StandardScaler 不同，CMVN 是逐句独立进行的，因此能够自适应地补偿不同句子的录制条件差异，而不依赖训练集的整体统计量。这一处理使分类器更关注语音内容的相对变化模式，而非绝对频谱值。

4.1.3 GMM 概率建模的优势

GMM 分类器相较于 KNN 的核心优势在于其概率生成建模的特性：

- (1) **时序信息保留：**GMM 直接对变长帧序列中的所有帧进行联合概率建模，而非像 KNN 那样将所有帧压缩为两个统计量（均值和方差）。这使得模型能够利用语音中丰富的帧级频谱分布信息；
- (2) **类内分布建模：**每个 GMM 通过 4 个高斯分量近似该类语音在特征空间中的多模态分布。考虑到同一数字在不同上下文中、由不同说话人发出时，其声学特征可能呈现多种模式（如清辅音段、元音段、过渡段），多分量 GMM 能够自然地捕捉这种多模态性；
- (3) **软判决与概率校准：**GMM 基于对数似然进行决策，其输出可以被解释为样本属于各类的相对置信度，比 KNN 的硬最近邻规则具有更好的泛化能力；
- (4) **小样本鲁棒性：**在小样本（每类仅 5 个训练样本）条件下，GMM 通过对所有帧进行密度估计来利用全部可用数据，而 KNN 仅依赖少数几个训练样本的距离排序，更容易受到个别异常帧的影响。

4.2 噪声鲁棒性分析

噪声实验结果表明, Advanced GMM 方法的性能随 SNR 下降呈现明显的退化趋势, 但退化程度相较 baseline 有明显改善。以 20 dB SNR 为例, GMM 平均准确率为 0.9125, 而 baseline 仅为 0.5025。

从现象层面分析, 噪声对 GMM 的影响主要体现在以下方面:

- (1) 加性噪声改变了每一帧的功率谱形状, 导致 MFCC 及其差分特征发生系统性偏移, 使测试帧在 GMM 似然空间中的分布偏离训练分布;
- (2) 在低 SNR (如 -10 dB) 下, 语音信号几乎被噪声淹没, 提取的特征主要反映噪声特性而非语音内容, 导致所有类别的对数似然趋近, 分类退化为近似随机猜测 (准确率 ≈ 0.10 , 与 10 类随机概率一致);
- (3) 噪声对 Δ 和 Δ^2 特征的影响尤为显著——高频噪声使相邻帧间出现大幅随机波动, 导致差分特征的信噪比低于静态 MFCC, 在低 SNR 下反可能成为干扰。

值得注意的是, 在 5 dB 至 20 dB 区间, GMM 准确率随 SNR 单调提升且标准差较小 (< 0.075), 表明该方法在该 SNR 范围内具有相对稳定的噪声鲁棒性。

4.3 与 Baseline 方法的性能对比

表 3 给出了 Baseline KNN 与 Advanced GMM 在纯净和不同噪声条件下的性能对比。

表 3: Baseline KNN 与 Advanced GMM 性能对比

SNR	Baseline KNN 准确率	Advanced GMM 准确率	提升幅度
Clean	0.8000	1.0000	+0.2000
20 dB	0.5025	0.9125	+0.4100
10 dB	0.2950	0.7250	+0.4300
0 dB	0.3500	0.3800	+0.0300

可以看出, Advanced GMM 在所有条件下均优于 baseline, 尤其在中高 SNR (10 dB–20 dB) 区间提升幅度最大 (约 +0.41–+0.43)。在 0 dB 及以下极端噪声条件下, 两种方法的差距缩小, 说明当噪声强度超过语音信号本身时, 特征提取本身成为瓶颈, 分类器的改进空间有限。

4.4 局限性与改进方向

尽管 Advanced GMM 方法在纯净和小噪声条件下表现出色, 但仍存在以下局限:

- (1) **对角协方差假设：**为简化参数估计，本方法使用对角协方差矩阵 (`diag`)，假设 39 维特征各维之间相互独立。这一假设在实际中并不完全成立——MFCC 相邻维度之间以及 MFCC 与 Δ/Δ^2 之间存在相关性。使用全协方差或 tied 协方差可能进一步提升性能；
- (2) **高斯分量数固定：** $K = 4$ 是根据经验选取的，未对不同分量数进行系统调优。分量数过少可能不足以捕获类内多模态分布，过多则在小样本下容易过拟合；
- (3) **小样本训练集：**每类仅 5 个训练样本，GMM 的 4 个分量共需估计 $4 \times (39 + 39) + 3 \approx 315$ 个参数（对角协方差下，含均值、方差与混合权重），训练数据量相对有限，可能导致参数估计不够精确；
- (4) **缺少有效语音帧筛选：**当前方法将所有帧（包括低能量静音帧）纳入 GMM 建模。在加噪条件下，静音段被填充为纯噪声帧，其分布与训练集中的静音帧分布不同，可能拉低整体对数似然；
- (5) **噪声场景单一：**噪声鲁棒性测试仅使用一种混合噪声类型，未评估对不同噪声类型（如语音 babble、街道噪声、音乐噪声等）的泛化能力。

未来改进方向可包括：(1) 引入语音活动检测 (VAD)，仅对有效语音帧进行 GMM 建模和评分；(2) 使用 Bayesian Information Criterion (BIC) 或交叉验证自动选择最优高斯分量数；(3) 尝试全协方差 GMM 或结合 UBM (Universal Background Model) 的自适应方法；(4) 在特征层面引入噪声抑制或谱减法预处理，提高低 SNR 下的特征质量。