



基于信号处理的孤立数字语音识别

于沛龙 景序 封宇凡 孟德轩

2026-05-30



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

任务背景与数据集



任务目标

- 面向 0-9 孤立数字语音，完成从信号分析到分类识别的完整流程
- 提取 MFCC 及动态特征，比较传统方法与深度学习方法
- 在混合噪声下测试模型鲁棒性，分析准确率随 SNR 的变化

数据集

- 数据：7 位说话人，每人朗读 0-9，共 70 段数字语音
- 采样率：16 kHz，单声道 MP3
- 预处理：基于短时能量进行端点检测并自


数据划分

划分	说话人	样本数
训练集	speaker 1-5	50
验证集	speaker 6-7	20


评估设置

- 无噪声：准确率 + 混淆矩阵
- 带噪声：-10, -5, 0, 5, 10, 15, 20 dB 七级 SNR
- 噪声：白噪声 + 1/f 噪声 + 50 Hz 工频干扰


信号分析：时域、频域与时频表示

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

(a) 时域波形：幅值随时间变化



(b) FFT 幅度谱：频率能量分布



(c) STFT 语谱图：时频联合表示

- 语音是非平稳信号，频谱会随时间变化
- STFT 通过分帧加窗保留局部频率信息

$$\text{STFT}\{x[n]\}(m, \omega) = \sum_n x[n]w[n - mR]e^{-j\omega n}$$


本实验采用 25 ms Hamming 窗，10 ms 帧移。

MFCC 特征提取流程


上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

梅尔频率倒谱系数 (MFCC)

- ① 预加重: $y[n] = x[n] - 0.97x[n-1]$
- ② 分帧加窗: 25 ms Hamming 窗, 10 ms 帧移
- ③ FFT → 功率谱: 获得短时频谱能量
- ④ Mel 滤波: 模拟人耳非线性频率感知
- ⑤ Log + DCT: 压缩动态范围并去相关
- ⑥ 动态特征: 加入 Δ, Δ^2 , 形成 39 维特征



13 维 MFCC 特征图



39 维 MFCC / Δ / Δ^2 特征图



整体算法流程与信号处理关联



两条技术路线

- **传统方法:** MFCC 统计特征 / 序列特征 + KNN / GMM
- **深度方法:** MFCC 特征图 + TinyKeywordCNN

信号与系统核心关联


- FFT / STFT: 频域分析与时频联合分析
- 预加重 / Mel 滤波: FIR 滤波与非线性频率映射
- DCT: 倒谱去相关与特征压缩

传统方法一：MFCC 统计特征 + KNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

特征与分类器

- 13 维 MFCC 逐帧取均值 μ 与标准差 σ
- 拼接为 26 维固定长度特征: $\mathbf{f} = [\mu, \sigma]$
- StandardScaler 标准化 + 1-NN ($k = 1$, 欧氏距离)
- 优点: 简单、可解释、适合小样本
- 缺点: 丢失时间顺序信息



纯净语音混淆矩阵 (准确率 80.0%, 16/20)


主要混淆: $0 \rightarrow 7$, $2 \rightarrow 8$, $4 \rightarrow 3$, $6 \rightarrow 9$

传统方法二：MFCC + Δ + Δ^2 + GMM

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

特征与模型

- 13 维 MFCC + Δ + Δ^2 = 39 维序列特征
- CMVN (倒谱均值方差归一化): 提升信道鲁棒性
- 每类训练一个 4 分量对角协方差 GMM
- 判决: 最大对数似然
$$\hat{y} = \arg \max_c \sum_t \log p(\mathbf{x}_t | \lambda_c)$$
- 优点: 天然适合变长序列, 无需压缩为固定维度



纯净语音混淆矩阵 (准确率 100.0%, 20/20)


20 条验证样本全部识别正确

深度学习方法: TinyKeywordCNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

模型架构与训练

- 输入: $39 \times T$ MFCC 特征图
- 4 个卷积块 (通道数
 $1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128$)
- Conv2d + BatchNorm + ReLU +
MaxPooling
- AdaptiveAvgPool(2,2) + Dropout(0.3) +
Linear $\rightarrow 10$
- 总参数量: 102,522
- 训练: AdamW (lr=0.001), 含数据增强,
早停 patience=20



纯净语音混淆矩阵 (准确率 95.0%, 19/20)

1 个错误: 数字 2 误判为 6

纯净语音识别结果对比



纯净语音识别结果


方法	维度	准确率
MFCC-stat + KNN	26 维	80.0%
MFCC+ Δ/Δ^2 +GMM	39 维	100.0%
TinyKeywordCNN (102k)	39 维	95.0%

- GMM: 20 条验证样本全部识别正确
- CNN: 1 个误判 (2 $\rightarrow$ 6)
- KNN: 4 个混淆, 说明统计特征丢失了部分时序信息

对比结论

- 动态特征能补充语音变化趋势
- GMM 保留变长序列信息, 适合小样本任务
- CNN 具有端到端建模能力, 但本实验验证集较小


噪声鲁棒性：KNN 基线

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

MFCC-stat + KNN

- 每个 SNR 重复 20 次，曲线展示均值与波动范围
- 低 SNR 下准确率明显下降
- 最高 SNR 下仍未达到 90%，说明均值/标准差统计特征鲁棒性有限

噪声鲁棒性: GMM 序列模型

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY


MFCC + Δ + Δ^2 + GMM

- 引入动态特征与 CMVN 归一化
- 中高 SNR 下性能提升明显
- 在 20 dB 时达到 90% 以上准确率 (91.25%)

噪声鲁棒性: TinyKeywordCNN



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



MFCC 特征图 + CNN

- 训练中加入增益、平移和随机噪声增强
- 低 SNR 下相对更稳
- CNN 为单次测试, 统计意义与 KNN/GMM 的重复均值不完全等价

总结与局限性



核心结论

- 1 MFCC 能有效刻画孤立数字语音的谱包络差异，是本任务的关键声学特征。
- 2 KNN 基线简单可解释，但均值/标准差统计会丢失时序信息，鲁棒性较弱。
- 3 GMM 保留变长序列特征，在纯净语音和中高 SNR 下表现最稳定；在 20 dB 时准确率达到 90
- 4 TinyKeywordCNN 受益于数据增强，在低 SNR 下表现相对平稳。

局限性

- 验证集仅 20 条，结果存在一定偶然性，统计意义有限

谢谢



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



Temporary page!

$\text{\LaTeX}$ was unable to guess the total number of pages correctly. As there was some unprocessed data that should have been added to the final page this extra page has been added to receive it.

If you rerun the document (without altering it) this surplus page will go away, because $\text{\LaTeX}$ now knows how many pages to expect for this document.