

任务背景与数据集




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

任务描述

- 孤立数字语音识别 (0-9), 小词汇量关键词识别
- 课程关联:** 傅里叶变换 (FFT)、短时傅里叶变换 (STFT)、滤波器组 (Mel 尺度)、倒谱分析 (DCT)
- 方法路线:** 传统信号处理 + 机器学习, 以及端到端深度学习

数据集

- 7 位说话人, 每人朗读 0-9 共 10 个数字
- 采样率 16 kHz, 单声道, MP3 格式



数字语音时域波形示例

评估指标


- 纯净语音识别准确率 + 混淆矩阵
- 混合噪声下鲁棒性——在 7 个 SNR 级别测试:
$$\text{SNR} = 10 \log_{10} (P_{\text{sig}} / P_{\text{noise}}) \text{ dB},$$

SNR 取


信号分析：从时域到频域



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY




(a) 时域波形：非平稳信号，幅值随时间剧烈变化



(b) FFT 幅度谱 (0-4000 Hz)：低频能量集中，

- **时域**：语音是非平稳信号，幅值随时间剧烈变化
- **FFT 幅度谱**：整体频域能量分布，低频能量集中
- **问题**：单一 FFT 丢失了频率随时间变化的信息



MFCC 特征提取流程


上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

梅尔频率倒谱系数 (MFCC)


- 1 预加重: $y[n] = x[n] - 0.97x[n-1]$ (补偿高频衰减)
- 2 分帧加窗: 25 ms Hamming 窗, 10 ms 帧移
- 3 FFT $\rightarrow$ 功率谱: $|FFT|^2$
- 4 Mel 滤波器组: 模拟人耳非线性频率感知

$$\text{mel}(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right)$$

低频密、高频疏的三角滤波器组



传统方法: 13 维 MFCC 特征图



整体算法流程与信号处理关联



端到端识别流程

- 1 原始语音 → 端点检测 → 切分
- 2 预加重 ($y[n] = x[n] - 0.97x[n-1]$, 一阶高通 FIR)
- 3 分帧加窗 (25 ms Hamming, 10 ms 帧移)
- 4 FFT → 功率谱 → Mel 滤波器组 (26 个三角滤波器)
- 5 Log 能量压缩 → DCT → 13 维 MFCC
- 6 动态特征 Δ, Δ^2 (一阶/二阶差分) → 39 维
- 7 特征构造 → 分类器 (KNN / GMM / CNN) → 预测 0-9

信号与系统核心关联

- FFT: 时域到频域的桥梁
- STFT: 非平稳信号的时频联合分析
- Mel 滤波器组: 模拟人耳非线性频率感知
- DCT: 频域去相关与能量压缩
- 预加重: 一阶高通 FIR 滤波器
- 分帧加窗: 短时平稳假设下的信号截断

两条技术路线

传统方法一：MFCC 统计特征 + KNN



特征构造


- 每段语音提取 13 维 MFCC，逐帧取均值与标准差
- 拼接为固定 26 维特征向量：

$$\mathbf{f} = [\mu_{\text{MFCC}} \quad \sigma_{\text{MFCC}}]$$

- 优点：简单、可解释、适合小样本
- 缺点：丢失时间顺序信息

分类器

- StandardScaler 标准化
- 1-NN ($k = 1$, 欧氏距离) 分类器



纯净语音混淆矩阵

- 纯净准确率：80.0% (16/20)

主要误差：0, 7, 2, 8

传统方法二：MFCC + Δ + Δ^2 + GMM




特征改进

- 13 维 MFCC + Δ + Δ^2 = 39 维序列特征
- 动态特征捕获时间演变信息
- CMVN (倒谱均值方差归一化): 提升对信道变化的鲁棒性

高斯混合模型 (GMM)

- 每类数字训练一个 4 分量对角协方差 GMM
- 判决: 对数似然最大



纯净语音混淆矩阵

- 纯净准确率: 100.0% (20/20)

深度学习方法: TinyKeywordCNN



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY


特征与模型

- 输入: MFCC + Δ + Δ^2 , $39 \times T$ 特征图
- 4 个卷积块 (Conv2d $\rightarrow$ BatchNorm $\rightarrow$ ReLU):

1 $\rightarrow$ 16 $\rightarrow$ 32 $\rightarrow$ 64 $\rightarrow$ 128 通道

- MaxPooling 逐步降采样
- AdaptiveAvgPool(2,2) + Dropout(0.3) + Linear $\rightarrow$ 10
- 总参数量: 102,522

训练策略



纯净语音混淆矩阵

- 纯净准确率: 95.0% (19/20)

识别结果对比与噪声鲁棒性



纯净语音识别结果

方法	维度	准确率
MFCC-stat + KNN	26 维	80.0%
MFCC + Δ/Δ^2 + GMM	39 维	100.0%
TinyKeywordCNN (102k)	39 维	95.0%

- **GMM** 利用完整序列信息，纯净条件下达 100%
- **CNN** 小样本下表现良好，但 1 个误判 (2→6)
- **KNN** 丢失时间结构，出现 4 个混淆错误

噪声鲁棒性 (SNR-Accuracy)

SNR (dB)	KNN	GMM	CNN
-10	0.158	0.100	0.20
-5	0.243	0.158	0.45
0	0.350	0.380	0.60
5	0.283	0.558	0.55
10	0.295	0.725	0.75
15	0.368	0.853	0.70
20	0.503	0.913	0.95

- **低 SNR** (-10, -5 dB): CNN 数据增强带来优势
- **中高 SNR** (≥ 5 dB): GMM 时序建模 + CMVN 领先

总结、局限性与团队分工



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

已完成工作

- 基于短时能量端点检测的自动语音切分
- 完整的 MFCC 特征提取流程 (预加重 → 分帧 → FFT → Mel 滤波 → DCT)
- 传统方法: MFCC-stat + KNN 基线, MFCC + Δ/Δ^2 + GMM 高级模型
- 深度方法: TinyKeywordCNN 端到端训练与评估
- 混合噪声下 7 级 SNR 鲁棒性评估

核心结论

基于使用叶分析的 MFCC 特征对数字

局限性

- 验证集仅 20 样本, 统计意义有限
- 单一混合噪声类型, 未测试白噪声/粉红噪声等单独类型
- 未进行说话人交叉验证
- 深度学习未尝试更先进架构 (残差、注意力等)

团队分工

成员 A 传统方法实现 (KNN, GMM)、噪声鲁棒性测试

成员 B 深度方法实现 (CNN)、模型训练与调优

谢谢



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

