



基于信号处理的孤立数字语音识别

ICE2606 信号与系统·课程大作业汇报

组员信息待补充

上海交通大学电子信息与电气工程学院

2026 年 5 月

孤立数字语音识别



上海交通大学

1/11

SJTU

任务背景与数据集




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

任务描述

- 孤立数字语音识别 (0-9), 小词汇量关键词识别
- 课程关联:** 傅里叶变换 (FFT)、短时傅里叶变换 (STFT)、滤波器组 (Mel 尺度)、倒谱分析 (DCT)
- 方法路线:** 传统信号处理 + 机器学习, 以及端到端深度学习

数据集

- 7 位说话人, 每人朗读 0-9 共 10 个数字
- 采样率 16 kHz, 单声道, MP3 格式




数字语音时域波形示例

评估指标


- 纯净语音识别准确率 + 混淆矩阵
- 混合噪声下鲁棒性——在 7 个 SNR 级别测试:
$$\text{SNR} = 10 \log_{10} (P_{\text{sig}} / P_{\text{noise}}) \text{ dB},$$

SNR 取

信号分析：从时域到频域


上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

(a) 时域波形：非平稳信号



(b) FFT 幅度谱 (0-4000 Hz)

- **时域**：语音是非平稳信号，幅值剧烈变化
- **FFT 幅度谱**：低频能量集中，存在谐波峰值
- **问题**：单一 FFT 丢失频率随时间变化的信息




MFCC 特征提取流程

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

梅尔频率倒谱系数 (MFCC)

- 1 预加重: $y[n] = x[n] - 0.97x[n-1]$
- 2 分帧加窗: 25 ms Hamming 窗, 10 ms 帧移
- 3 FFT $\rightarrow$ 功率谱
- 4 Mel 滤波器组 (26 个三角滤波器, 低频密、高频疏)
- 5 取对数: 压缩能量动态范围
- 6 DCT: 去相关, 取前 13 维作为倒谱系数
- 7 动态特征: Δ 和 Δ^2 (一阶/二阶差分)



13 维 MFCC 特征图 (传统方法)



整体算法流程与信号处理关联



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

预处理



两条技术路线

- **传统方法**: 手工特征 + KNN (统计) / GMM (序列)
- **深度方法**: MFCC 特征图 + 卷积神经网络

信号与系统核心关联


- FFT: 时域到频域的桥梁
- STFT: 非平稳信号的时频联合分析
- Mel 滤波组: 模拟人耳非线性频率感知

传统方法一：MFCC 统计特征 + KNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

特征与分类器

- 13 维 MFCC 逐帧取均值 μ 与标准差 σ
- 拼接为 26 维固定长度特征: $\mathbf{f} = [\mu, \sigma]$
- StandardScaler 标准化 + 1-NN ($k = 1$, 欧氏距离)
- 优点: 简单、可解释、适合小样本
- 缺点: 丢失时间顺序信息



纯净语音混淆矩阵 (20 条验证样本)


准确率: 80.0% (16/20)

传统方法二：MFCC + Δ + Δ^2 + GMM



特征与模型

- 13 维 MFCC + Δ + Δ^2 = 39 维序列特征
- CMVN (倒谱均值方差归一化): 提升信道鲁棒性
- 每类训练一个 4 分量对角协方差 GMM
- 判决: 最大对数似然
$$\hat{y} = \arg \max_c \sum_t \log p(\mathbf{x}_t | \lambda_c)$$
- 优点: 天然适合变长序列, 无需压缩为固定维度



纯净语音混淆矩阵 (20 条验证样本)

● 准确率: 100.0% (20/20)


深度学习方法: TinyKeywordCNN



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

模型架构与训练

- 输入: $39 \times T$ MFCC 特征图
- 4 个卷积块 (通道数
 $1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128$)
- Conv2d + BatchNorm + ReLU +
MaxPooling
- AdaptiveAvgPool(2,2) + Dropout(0.3) +
Linear $\rightarrow 10$
- 总参数量: 102,522
- 训练: AdamW (lr=0.001), 数据增强
($\pm 3\text{dB}$ 增益、 $\pm 120\text{ms}$ 平移、随机加噪)
- 早停 patience=20, 最优 epoch 37



纯净语音混淆矩阵 (20 条验证样本)

• 准确率: 95.0% (19/20)

识别结果对比与噪声鲁棒性




纯净语音识别结果

方法	维度	准确率
MFCC-stat + KNN	26 维	80.0%
MFCC+ Δ/Δ^2 +GMM	39 维	100.0%
TinyKeywordCNN (102k)	39 维	95.0%

- GMM: 20 条验证样本全部正确
- CNN: 1 个误判 (2 $\rightarrow$ 6), KNN: 4 个混淆

噪声鲁棒性 (SNR-Accuracy)



KNN/GMM 为 20 次重复均值; CNN 为单次测试, 统计意义不完全等价

- 总体上准确率随 SNR 提高而上升; 由于验证集较小且 CNN 为单次测试, 局部存在波动

• 低 SNR (-10 ~ -5 dB): CNN 数据增强带来优势

总结、局限性与团队分工



已完成工作

- 基于短时能量端点检测的自动语音切分
- 完整 MFCC 特征提取 (预加重 $\rightarrow$ 分帧 $\rightarrow$ FFT $\rightarrow$ Mel 滤波 $\rightarrow$ DCT)
- 传统方法: KNN 基线 + GMM 模型
- 深度方法: TinyKeywordCNN 训练与评估
- 混合噪声下 7 级 SNR 鲁棒性评估

核心结论

- ① MFCC 特征对数字语音有良好区分度

局限性

- 验证集仅 20 样本, 统计意义有限
- 单一混合噪声类型, 未测试各噪声单独影响
- 未进行说话人交叉验证
- 深度学习未尝试残差、注意力等架构

团队分工

- 组员信息待补充
- 组员信息待补充
- 组员信息待补充

谢谢



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

