



基于信号处理的孤立数字语音识别

于沛龙 景序 封宇凡 孟德轩

2026-05-29



上海交通大学

SHANGHAI JIAO TONG UNIVERSITY


任务背景与数据集




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

任务描述

- 孤立数字语音识别 (0-9), 小词汇量关键词识别
- 课程关联: FFT、STFT、Mel 滤波器组、倒谱分析 (DCT)
- 7 位说话人, 16 kHz 单声道 MP3, 短时能量端点检测自动切分
- 训练集 50 条 (speaker 1-5), 验证集 20 条 (speaker 6-7)
- 评估: 纯净准确率 + 混合噪声 7 级 SNR (-10 ~ 20 dB) 鲁棒性




数字语音时域波形




FFT 幅度谱


信号分析：时域、频域与时频表示

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

(a) 时域波形



(b) FFT 幅度谱 (0-4000 Hz)



(c) STFT 语谱图

语音是非平稳信号，单一 FFT 丢失频率随时间变化的信息。STFT 通过分帧加窗实现时频联合分析：

$$\text{STFT}\{x[n]\}(m, \omega) = \sum_{n=-\infty}^{\infty} x[n]w[n-mR]e^{-j\omega n}$$


MFCC 特征提取流程




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

梅尔频率倒谱系数 (MFCC)

- 1 **预加重**: $y[n] = x[n] - 0.97x[n-1]$ (FIR 高通)
- 2 **分帧加窗**: 25 ms Hamming 窗, 10 ms 帧移
- 3 **FFT $\rightarrow$ 功率谱 $\rightarrow$ Mel 滤波**: 26 个三角滤波器 (低频密、高频疏)
- 4 **取对数 + DCT**: 压缩动态范围, 去相关, 取前 13 维
- 5 **动态特征**: Δ 和 Δ^2 (一阶/二阶差分) $\rightarrow$ 39 维



13 维 MFCC (传统方法)




39 维 MFCC + Δ + Δ^2 (深度方法)

整体算法流程与信号处理关联



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



两条技术路线

- **传统**：手工特征 + KNN（统计） / GMM（序列）
- **深度**：MFCC 特征图 + 卷积神经网络

信号与系统核心关联


- FFT：时域到频域的桥梁；STFT：时频联合分析
- Mel 滤波器组：模拟人耳非线性频率感知
- DCT：频域去相关与能量压缩
- 预加重/分帧加窗：FIR 滤波与短时平稳假设

传统方法一：MFCC 统计特征 + KNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

特征与分类器

- 13 维 MFCC 逐帧取均值 μ 与标准差 σ
- 拼接为 26 维固定长度特征: $\mathbf{f} = [\mu, \sigma]$
- StandardScaler 标准化 + 1-NN ($k = 1$, 欧氏距离)
- 优点: 简单、可解释、适合小样本
- 缺点: 丢失时间顺序信息



纯净语音混淆矩阵 (准确率 80.0%, 16/20)


主要混淆: $0 \rightarrow 7$, $2 \rightarrow 8$, $4 \rightarrow 3$, $6 \rightarrow 9$

传统方法二：MFCC + Δ + Δ^2 + GMM



特征与模型

- 13 维 MFCC + Δ + Δ^2 = 39 维序列特征
- CMVN (倒谱均值方差归一化): 提升信道鲁棒性
- 每类训练一个 4 分量对角协方差 GMM
- 判决: 最大对数似然
$$\hat{y} = \arg \max_c \sum_t \log p(\mathbf{x}_t | \lambda_c)$$
- 优点: 天然适合变长序列, 无需压缩为固定维度



纯净语音混淆矩阵 (准确率 100.0%, 20/20)


20 条验证样本全部识别正确

深度学习方法: TinyKeywordCNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

模型架构与训练

- 输入: $39 \times T$ MFCC 特征图
- 4 个卷积块 (通道数
 $1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128$)
- Conv2d + BatchNorm + ReLU +
MaxPooling
- AdaptiveAvgPool(2,2) + Dropout(0.3) +
Linear $\rightarrow 10$
- 总参数量: 102,522
- 训练: AdamW (lr=0.001), 含数据增强,
早停 patience=20



纯净语音混淆矩阵 (准确率 95.0%, 19/20)

1 个错误: 数字 2 误判为 6


识别结果对比与噪声鲁棒性



纯净语音识别结果

方法	维度	准确率
MFCC-stat + KNN	26 维	80.0%
MFCC+ Δ/Δ^2 +GMM	39 维	100.0%
TinyKeywordCNN (102k)	39 维	95.0%

噪声鲁棒性 (SNR-Accuracy)



- GMM: 20 条验证样本全部正确
- CNN: 1 个误判 (2 $\rightarrow$ 6), KNN: 4 个混淆

KNN/GMM 为 20 次重复均值; CNN 为单次测试, 统计意义不完全等价

- 准确率整体随 SNR 提高呈上升趋势, 但非严格单调; 验证集较小且 CNN 为单次测试, 局部存在波动
- GMM 与 CNN 在 20 dB SNR 时首次达到 90% 以上 (各 91.25%, 95%), KNN 在所有 SNR 下均未达到 90%
- 低 SNR (-10, -5 dB): CNN 数据增强占优; 中高 SNR (≥ 5 dB): GMM 时序建模 + CMVN 占优

总结、局限性与团队分工



已完成工作

- 基于短时能量端点检测的自动语音切分
- 完整 MFCC 特征提取 (预加重 $\rightarrow$ 分帧 $\rightarrow$ FFT $\rightarrow$ Mel 滤波 $\rightarrow$ DCT)
- 传统方法: KNN + GMM; 深度方法: TinyKeywordCNN
- 混合噪声下 7 级 SNR 鲁棒性评估

核心结论

- ① MFCC 特征对数字语音有良好区分度
- ② 动态特征、序列建模与 CMVN 归一化显著提升传统方法性能
- ③ 纯净语音和中高 SNR 下 GMM 更优; 低

局限性

- 验证集仅 20 样本, 统计意义有限
- 单一混合噪声类型, 未测试各噪声单独影响
- 未进行说话人交叉验证
- 深度学习未尝试残差、注意力等架构

谢谢



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

