



基于信号处理的孤立数字语音识别

于沛龙 景序 封宇凡 孟德轩

2026-05-30



上海交通大学

SHANGHAI JIAO TONG UNIVERSITY

任务背景与数据集



任务目标

- 面向 0-9 孤立数字语音，完成从信号分析到分类识别的完整流程
- 提取 MFCC 及动态特征，比较传统与深度学习方法
- 在混合噪声下测试模型鲁棒性，分析准确率随 SNR 的变化

数据集

- 数据：7 位说话人，每人朗读 0-9，共 70 段语音
- 采样率：16 kHz，单声道 MP3
- 预处理：基于短时能量进行端点检测并自动切分


数据划分

划分	说话人	样本数
训练集	speaker 1-5	50
验证集	speaker 6-7	20


评估设置

- 无噪声：准确率 + 混淆矩阵
- 带噪声：-10, -5, 0, 5, 10, 15, 20 dB 七级 SNR
- 噪声：白噪声 + 1/f 噪声 + 50 Hz 工频干扰

信号分析：时域、频域与时频表示


上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

(a) 时域波形：反映语音的能量包络与起止位置



(b) FFT 幅度谱：反映整体频率能量分布

本实验采用 25 ms Hamming 窗，10 ms 帧移。



(c) STFT 语谱图：反映频谱随时间的变化

- 语音是典型非平稳信号，整体 FFT 会丢失时间变化信息
- 分帧加窗后进行 STFT，可同时观察时间、频率和能量分布
- 这些分析结果为后续端点检测、MFCC 特征提取和噪声鲁棒性测试提供依据

MFCC 特征提取流程




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY


梅尔频率倒谱系数 (MFCC)

- ① **预加重**: $y[n] = x[n] - 0.97x[n-1]$
- ② **分帧加窗**: 25 ms Hamming 窗, 10 ms 帧移
- ③ **FFT → 功率谱**: 获得短时频谱能量
- ④ **Mel 滤波**: 模拟人耳非线性频率感知
- ⑤ **Log + DCT**: 压缩动态范围并去相关
- ⑥ **动态特征**: 在 13 维 MFCC 基础上加入 Δ , Δ^2 , 形成 39 维特征

注: C0 主要反映整体能量, 数值较大, 易掩盖其余倒谱系数的细节。因此 13 维 MFCC 图在可视化时省略 C0; 39 维图保留完整动态特征结构。



13 维 MFCC 特征图 (可视化时未显示 C0)



39 维 MFCC / Δ / Δ^2 特征图



整体算法流程与信号处理关联



两条技术路线

- **传统方法:** KNN 使用 MFCC 统计特征; GMM 使用 MFCC + Δ + Δ^2 序列特征
- **深度方法:** CNN 使用 MFCC 动态特征图进行卷积分类

信号与系统核心关联


- 语音建模: 离散非平稳信号 + 混合噪声
- FFT / STFT: 频域分解与时频联合分析
- 预加重: 一阶 FIR 高通系统
- Mel + DCT: 频域加权、倒谱压缩与去相关

传统方法一：MFCC 统计特征 + KNN



特征与分类器

- 13 维 MFCC 逐帧取均值 μ 与标准差 σ
- 拼接为 26 维固定长度特征: $\mathbf{f} = [\mu, \sigma]$
- StandardScaler 标准化 + 1-NN ($k = 1$, 欧氏距离)
- 优点: 简单、可解释、适合小样本
- 缺点: 统计池化丢失时间顺序信息, 加入 Δ 、 Δ^2 后验证准确率下降, 说明小样本高维特征下欧氏距离不稳定



纯净语音混淆矩阵 (准确率 80.0%, 16/20)


主要混淆: $0 \rightarrow 7$, $2 \rightarrow 8$, $4 \rightarrow 3$, $6 \rightarrow 9$

传统方法二：MFCC + Δ + Δ^2 + GMM

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

特征与模型

- 引入 MFCC + Δ + Δ^2 的 39 维帧级序列特征
- CMVN (倒谱均值方差归一化): 提升信道鲁棒性
- 每类训练一个 4 分量对角协方差 GMM
- 判决: 最大对数似然
$$\hat{y} = \arg \max_c \sum_t \log p(\mathbf{x}_t | \lambda_c)$$
- 优点: 相比 KNN 统计池化, GMM 更适合建模语音的时序变化



纯净语音混淆矩阵 (准确率 100.0%, 20/20)


20 条验证样本全部识别正确

深度学习方法: TinyKeywordCNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

模型架构与训练

- 输入: $39 \times T$ MFCC 特征图
- 4 个卷积块 (通道数
 $1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128$)
- Conv2d + BatchNorm + ReLU +
MaxPooling
- AdaptiveAvgPool(2,2) + Dropout(0.3) +
Linear $\rightarrow 10$
- 总参数量: 102,522
- 训练: AdamW (lr=0.001), 含数据增强,
早停 patience=30



纯净语音混淆矩阵 (准确率 95.0%, 19/20)

1 个错误: 数字 2 误判为 6

纯净语音识别结果对比



纯净语音识别结果

方法	输入特征	准确率
MFCC-stat + KNN	26 维	80.0%
MFCC+ Δ/Δ^2 +GMM	39 维	100.0%
TinyKeywordCNN (102k)	39 维	95.0%

- GMM: 20 条验证样本全部识别正确
- CNN: 1 个误判 (2 $\rightarrow$ 6)
- KNN: 4 个混淆, 说明统计特征丢失了部分时序信息


对比结论

- KNN 简单可解释, 但均值/标准差统计池化会丢失帧级时间顺序
- GMM 保留变长帧序列信息, 更适合建模语音的动态变化
- CNN 利用 MFCC 特征图进行卷积分类, 具有较强表示能力; 但验证集较小, 结果仍需结合噪声测试进一步判断

噪声鲁棒性: KNN 基线




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



MFCC-stat + KNN

- 每个 SNR 重复 20 次, 曲线展示均值与标准差
- 低 SNR 下准确率明显下降, 20 dB 时也仅恢复到约 50%
- 说明均值/标准差统计特征对噪声敏感, 且 KNN 的欧氏距离度量在带噪条件下不稳定

噪声鲁棒性: GMM 序列模型

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY


MFCC + Δ + Δ^2 + GMM

- 引入动态特征与 CMVN 归一化
- 中高 SNR 下性能提升明显, 误差棒整体较小
- 准确率随 SNR 提升稳定上升, 20 dB 时达到 91.25%

噪声鲁棒性: TinyKeywordCNN



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



MFCC 特征图 + CNN

- 训练中加入增益、平移和随机噪声增强
- 低 SNR 下下降较缓, 但单次测试统计意义有限
- CNN 为单次测试, 因此主要用于观察趋势, 不与 KNN/GMM 的均值曲线作严格统计比较

总结与局限性



核心结论

- ① MFCC 能有效刻画孤立数字语音的谱包络差异，是本任务的关键声学特征。在混合噪声测试中，各模型准确率整体随 SNR 提升而改善。
- ② KNN 基线简单可解释，但均值/标准差统计池化会丢失帧级时序信息，鲁棒性较弱。
- ③ GMM 保留变长帧序列特征，在纯净语音和中高 SNR 下表现最稳定；20 dB 时准确率达到 91.25%。
- ④ TinyKeywordCNN 受益于数据增强，在低 SNR 下仍有一定识别能力，但单次测试统计意义有限。

局限性

- 验证集仅 20 条，结果存在一定偶然性，统计意义有限。
- 本实验主要考察混合噪声下的整体鲁棒性，未进一步拆分单类噪声影响。
- 未进行更完整的说话人交叉验证。

团队分工



- 于沛龙：传统方法基线、噪声鲁棒性测试、PPT 整理；
- 景序：GMM 序列模型、传统方法优化与结果分析；
- 封宇凡：深度学习模型设计、训练与评估；
- 孟德轩：数据处理、实验对照、报告与展示材料整理。

谢谢



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

