



# 基于信号处理的孤立数字语音识别

ICE2606 信号与系统·课程大作业汇报

组员信息待补充

上海交通大学电子信息与电气工程学院

2026 年 5 月

孤立数字语音识别



上海交通大学

1/11

SJTU


# 任务背景与数据集




上海交通大学  
SHANGHAI JIAO TONG UNIVERSITY

## 任务描述

- 孤立数字语音识别 (0-9), 小词汇量关键词识别
- 课程关联: FFT、STFT、Mel 滤波器组、倒谱分析 (DCT)
- 7 位说话人, 16 kHz 单声道 MP3, 短时能量端点检测自动切分
- 训练集 50 条 (speaker 1-5), 验证集 20 条 (speaker 6-7)
- 评估: 纯净准确率 + 混合噪声 7 级 SNR (-10 ~ 20 dB) 鲁棒性



数字语音时域波形




FFT 幅度谱


# 信号分析：时域、频域与时频表示




上海交通大学  
SHANGHAI JIAO TONG UNIVERSITY



(a) 时域波形



(b) FFT 幅度谱 (0-4000 Hz)



(c) STFT 语谱图

语音是非平稳信号，单一 FFT 丢失频率随时间变化的信息。STFT 通过分帧加窗实现时频联合分析：


$$\text{STFT}\{x[n]\}(m, \omega) = \sum_{n=-\infty}^{\infty} x[n]w[n-mR]e^{-j\omega n}$$

# MFCC 特征提取流程


上海交通大学  
SHANGHAI JIAO TONG UNIVERSITY

## 梅尔频率倒谱系数 (MFCC)

- 1 **预加重**:  $y[n] = x[n] - 0.97x[n-1]$  (FIR 高通)
- 2 **分帧加窗**: 25 ms Hamming 窗, 10 ms 帧移
- 3 **FFT  $\rightarrow$  功率谱  $\rightarrow$  Mel 滤波**: 26 个三角滤波器 (低频密、高频疏)
- 4 **取对数 + DCT**: 压缩动态范围, 去相关, 取前 13 维
- 5 **动态特征**:  $\Delta$  和  $\Delta^2$  (一阶/二阶差分)  $\rightarrow$  39 维




13 维 MFCC (传统方法)

39 维 MFCC +  $\Delta$  +  $\Delta^2$  (深度方法)





# 整体算法流程与信号处理关联

## 预处理



## 特征提取



## 分类器

## 两条技术路线

- **传统**: 手工特征 + KNN (统计) / GMM (序列)
- **深度**: MFCC 特征图 + 卷积神经网络

## 信号与系统核心关联

- FFT: 时域到频域的桥梁; STFT: 时频联合分析
- Mel 滤波器组: 模拟人耳非线性频率感知
- DCT: 频域去相关与能量压缩
- 预加重/分帧加窗: FIR 滤波与短时平稳假设


# 传统方法一：MFCC 统计特征 + KNN



上海交通大学  
SHANGHAI JIAO TONG UNIVERSITY

## 特征与分类器

- 13 维 MFCC 逐帧取均值  $\mu$  与标准差  $\sigma$
- 拼接为 26 维固定长度特征:  $\mathbf{f} = [\mu, \sigma]$
- StandardScaler 标准化 + 1-NN ( $k = 1$ , 欧氏距离)
- 优点: 简单、可解释、适合小样本
- 缺点: 丢失时间顺序信息



纯净语音混淆矩阵 (准确率 80.0%, 16/20)


- 主要混淆:  $0 \rightarrow 7$ ,  $2 \rightarrow 8$ ,  $4 \rightarrow 3$ ,  $6 \rightarrow 9$

## 传统方法二：MFCC + $\Delta$ + $\Delta^2$ + GMM



### 特征与模型

- 13 维 MFCC +  $\Delta$  +  $\Delta^2$  = 39 维序列特征
- CMVN (倒谱均值方差归一化): 提升信道鲁棒性
- 每类训练一个 4 分量对角协方差 GMM
- 判决: 最大对数似然
$$\hat{y} = \arg \max_c \sum_t \log p(\mathbf{x}_t | \lambda_c)$$
- 优点: 天然适合变长序列, 无需压缩为固定维度



纯净语音混淆矩阵 (准确率 100.0%, 20/20)


- 20 条验证样本全部识别正确

# 深度学习方法: TinyKeywordCNN

上海交通大学  
SHANGHAI JIAO TONG UNIVERSITY

## 模型架构与训练

- 输入:  $39 \times T$  MFCC 特征图
- 4 个卷积块 (通道数  
 $1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128$ )
- Conv2d + BatchNorm + ReLU +  
MaxPooling
- AdaptiveAvgPool(2,2) + Dropout(0.3) +  
Linear  $\rightarrow 10$
- 总参数量: 102,522
- 训练: AdamW (lr=0.001), 含数据增强,  
早停 patience=20



纯净语音混淆矩阵 (准确率 95.0%, 19/20)

- 1 个错误: 数字 2 误判为 6




# 识别结果对比与噪声鲁棒性



## 纯净语音识别结果

| 方法                           | 维度   | 准确率    |
|------------------------------|------|--------|
| MFCC-stat + KNN              | 26 维 | 80.0%  |
| MFCC+ $\Delta/\Delta^2$ +GMM | 39 维 | 100.0% |
| TinyKeywordCNN (102k)        | 39 维 | 95.0%  |

## 噪声鲁棒性 (SNR-Accuracy)



- GMM: 20 条验证样本全部正确
- CNN: 1 个误判 (2  $\rightarrow$  6), KNN: 4 个混淆

KNN/GMM 为 20 次重复均值; CNN 为单次测试, 统计意义不完全等价

- 准确率整体随 SNR 提高呈上升趋势, 但非严格单调; 验证集较小且 CNN 为单次测试, 局部存在波动
- GMM 与 CNN 在 20 dB SNR 时首次达到 90% 以上 (各 91.25%, 95%), KNN 在所有 SNR 下均未达到 90%
- 低 SNR (-10, -5 dB): CNN 数据增强占优; 中高 SNR ( $\geq 5$  dB): GMM 时序建模 + CMVN 占优

# 总结、局限性与团队分工



## 已完成工作

- 基于短时能量端点检测的自动语音切分
- 完整 MFCC 特征提取 (预加重  $\rightarrow$  分帧  $\rightarrow$  FFT  $\rightarrow$  Mel 滤波  $\rightarrow$  DCT)
- 传统方法: KNN + GMM; 深度方法: TinyKeywordCNN
- 混合噪声下 7 级 SNR 鲁棒性评估

## 核心结论

- ① MFCC 特征对数字语音有良好区分度
- ② 动态特征、序列建模与 CMVN 归一化显著提升传统方法性能
- ③ 纯净语音和中高 SNR 下 GMM 更优; 低

## 局限性

- 验证集仅 20 样本, 统计意义有限
- 单一混合噪声类型, 未测试各噪声单独影响
- 未进行说话人交叉验证
- 深度学习未尝试残差、注意力等架构

## 团队分工

姓名 : 负责 XXX

姓名 : 负责 XXX

姓名 : 负责 XXX

姓名 : 负责 XXX

# 谢谢



上海交通大学  
SHANGHAI JIAO TONG UNIVERSITY

