



基于信号处理的孤立数字语音识别

于沛龙 景序 封宇凡 孟德轩

2026-05-30



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY


- 识别孤立数字语音 (0-9)
- 提取 MFCC 特征并完成分类
- 比较传统方法与深度学习方法
- 测试混合噪声下的鲁棒性

- 7 位说话人, 每人朗读 0-9
- 16 kHz, 单声道 MP3
- 短时能量端点检测自动切分


划分	说话人	样本数
训练集	speaker 1-5	50
验证集	speaker 6-7	20

- 纯净语音：准确率 + 混淆矩阵
- 带噪语音：7 级 SNR 鲁棒性
- SNR: $-10, -5, 0, 5, 10, 15, 20$ dB
- 噪声：白噪声 + $1/f$ 噪声 + 50 Hz 工频


信号分析：时域、频域与时频表示

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

(a) 时域波形：幅值随时间变化



(b) FFT 幅度谱：频率能量分布



(c) STFT 语谱图：时频联合表示

- 语音是非平稳信号，频谱会随时间变化
- STFT 通过分帧加窗保留局部频率信息

$$\text{STFT}\{x[n]\}(m, \omega) = \sum_n x[n]w[n - mR]e^{-j\omega n}$$


本实验采用 25 ms Hamming 窗，10 ms 帧移。

MFCC 特征提取流程


上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

梅尔频率倒谱系数 (MFCC)

- ① 预加重: $y[n] = x[n] - 0.97x[n-1]$
- ② 分帧加窗: 25 ms Hamming 窗, 10 ms 帧移
- ③ FFT → 功率谱: 获得短时频谱能量
- ④ Mel 滤波: 模拟人耳非线性频率感知
- ⑤ Log + DCT: 压缩动态范围并去相关
- ⑥ 动态特征: 加入 Δ, Δ^2 , 形成 39 维特征



13 维 MFCC 特征图



39 维 MFCC / Δ / Δ^2 特征图



整体算法流程与信号处理关联



两条技术路线

- **传统方法:** MFCC 统计特征 / 序列特征 + KNN / GMM
- **深度方法:** MFCC 特征图 + TinyKeywordCNN

信号与系统核心关联


- FFT / STFT: 频域分析与时频联合分析
- 预加重 / Mel 滤波: FIR 滤波与非线性频率映射
- DCT: 倒谱去相关与特征压缩

传统方法一：MFCC 统计特征 + KNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

特征与分类器

- 13 维 MFCC 逐帧取均值 μ 与标准差 σ
- 拼接为 26 维固定长度特征: $\mathbf{f} = [\mu, \sigma]$
- StandardScaler 标准化 + 1-NN ($k = 1$, 欧氏距离)
- 优点: 简单、可解释、适合小样本
- 缺点: 丢失时间顺序信息



纯净语音混淆矩阵 (准确率 80.0%, 16/20)


主要混淆: $0 \rightarrow 7$, $2 \rightarrow 8$, $4 \rightarrow 3$, $6 \rightarrow 9$

传统方法二：MFCC + Δ + Δ^2 + GMM

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

特征与模型

- 13 维 MFCC + Δ + Δ^2 = 39 维序列特征
- CMVN (倒谱均值方差归一化): 提升信道鲁棒性
- 每类训练一个 4 分量对角协方差 GMM
- 判决: 最大对数似然
$$\hat{y} = \arg \max_c \sum_t \log p(\mathbf{x}_t | \lambda_c)$$
- 优点: 天然适合变长序列, 无需压缩为固定维度



纯净语音混淆矩阵 (准确率 100.0%, 20/20)


20 条验证样本全部识别正确

深度学习方法: TinyKeywordCNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

模型架构与训练

- 输入: $39 \times T$ MFCC 特征图
- 4 个卷积块 (通道数
 $1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128$)
- Conv2d + BatchNorm + ReLU +
MaxPooling
- AdaptiveAvgPool(2,2) + Dropout(0.3) +
Linear $\rightarrow 10$
- 总参数量: 102,522
- 训练: AdamW (lr=0.001), 含数据增强,
早停 patience=20



纯净语音混淆矩阵 (准确率 95.0%, 19/20)

1 个错误: 数字 2 误判为 6

纯净语音识别结果对比



纯净语音识别结果


方法	维度	准确率
MFCC-stat + KNN	26 维	80.0%
MFCC+ Δ/Δ^2 +GMM	39 维	100.0%
TinyKeywordCNN (102k)	39 维	95.0%

- GMM: 20 条验证样本全部识别正确
- CNN: 1 个误判 (2 $\rightarrow$ 6)
- KNN: 4 个混淆, 说明统计特征丢失了部分时序信息

对比结论

- 动态特征能补充语音变化趋势
- GMM 保留变长序列信息, 适合小样本任务
- CNN 具有端到端建模能力, 但本实验验证集较小


噪声鲁棒性：KNN 基线

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

MFCC-stat + KNN

- 每个 SNR 重复 20 次，曲线展示均值与波动范围
- 低 SNR 下准确率明显下降
- 最高 SNR 下仍未达到 90%，说明均值/标准差统计特征鲁棒性有限

噪声鲁棒性: GMM 序列模型

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY


MFCC + Δ + Δ^2 + GMM

- 引入动态特征与 CMVN 归一化
- 中高 SNR 下性能提升明显
- 在 20 dB 时达到 90% 以上准确率 (91.25%)

噪声鲁棒性: TinyKeywordCNN



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



MFCC 特征图 + CNN

- 训练中加入增益、平移和随机噪声增强
- 低 SNR 下相对更稳
- CNN 为单次测试, 统计意义与 KNN/GMM 的重复均值不完全等价

总结与局限性



已完成工作

- 基于短时能量的自动端点检测
- 完整 MFCC 特征提取流程
- 传统方法：KNN 基线 + GMM 序列模型
- 深度方法：TinyKeywordCNN
- 7 级 SNR 混合噪声鲁棒性评估

核心结论

- ① MFCC 对孤立数字语音具有良好区分度
- ② GMM 在纯净语音与中高 SNR 下表现最好
- ③ CNN 在低 SNR 下受益于数据增强，但单次测试统计意义有限

局限性

- 验证集仅 20 条，统计意义有限
- 仅测试统一混合噪声，未拆分单类噪声影响
- 未进行说话人交叉验证

谢谢



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

