



基于信号处理的孤立数字语音识别

于沛龙 景序 封宇凡 孟德轩

2026-05-29



上海交通大学

SHANGHAI JIAO TONG UNIVERSITY

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

- 识别孤立数字语音 (0-9)
- 提取 MFCC 特征并完成分类
- 比较传统方法与深度学习方法
- 测试混合噪声下的鲁棒性

数据集

- 7 位说话人, 每人朗读 0-9
- 16 kHz, 单声道 MP3
- 短时能量端点检测自动切分


数据划分

划分	说话人	样本数
训练集	speaker 1-5	50
验证集	speaker 6-7	20


评估设置

- 纯净语音：准确率 + 混淆矩阵
- 带噪语音：7 级 SNR 鲁棒性
- SNR: $-10, -5, 0, 5, 10, 15, 20$ dB
- 噪声：白噪声 + $1/f$ 噪声 + 50 Hz 工频


信号分析：时域、频域与时频表示

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

(a) 时域波形：幅值随时间变化



(b) FFT 幅度谱：频率能量分布



(c) STFT 语谱图：时频联合表示

- 语音是非平稳信号，频谱会随时间变化
- STFT 通过分帧加窗保留局部频率信息

$$\text{STFT}\{x[n]\}(m, \omega) = \sum_n x[n]w[n - mR]e^{-j\omega n}$$


本实验采用 25 ms Hamming 窗，10 ms 帧移。

MFCC 特征提取流程


上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

梅尔频率倒谱系数 (MFCC)

- ① 预加重: $y[n] = x[n] - 0.97x[n-1]$
- ② 分帧加窗: 25 ms Hamming 窗, 10 ms 帧移
- ③ FFT $\rightarrow$ 功率谱: 获得短时频谱能量
- ④ Mel 滤波: 模拟人耳非线性频率感知
- ⑤ Log + DCT: 压缩动态范围并去相关
- ⑥ 动态特征: 加入 Δ, Δ^2 , 形成 39 维特征



13 维 MFCC 特征图



39 维 MFCC / Δ / Δ^2 特征图

整体算法流程与信号处理关联



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



两条技术路线

- **传统方法:** MFCC 统计特征 / 序列特征 + KNN / GMM
- **深度方法:** MFCC 特征图 + TinyKeywordCNN

信号与系统核心关联


- FFT / STFT: 频域分析与时频联合分析
- 预加重 / Mel 滤波: FIR 滤波与非线性频率映射
- DCT: 倒谱去相关与特征压缩

传统方法一：MFCC 统计特征 + KNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

特征与分类器

- 13 维 MFCC 逐帧取均值 μ 与标准差 σ
- 拼接为 26 维固定长度特征: $\mathbf{f} = [\mu, \sigma]$
- StandardScaler 标准化 + 1-NN ($k = 1$, 欧氏距离)
- 优点: 简单、可解释、适合小样本
- 缺点: 丢失时间顺序信息



纯净语音混淆矩阵 (准确率 80.0%, 16/20)


主要混淆: $0 \rightarrow 7$, $2 \rightarrow 8$, $4 \rightarrow 3$, $6 \rightarrow 9$

传统方法二：MFCC + Δ + Δ^2 + GMM



特征与模型

- 13 维 MFCC + Δ + Δ^2 = 39 维序列特征
- CMVN (倒谱均值方差归一化): 提升信道鲁棒性
- 每类训练一个 4 分量对角协方差 GMM
- 判决: 最大对数似然
$$\hat{y} = \arg \max_c \sum_t \log p(\mathbf{x}_t | \lambda_c)$$
- 优点: 天然适合变长序列, 无需压缩为固定维度



纯净语音混淆矩阵 (准确率 100.0%, 20/20)


20 条验证样本全部识别正确

深度学习方法: TinyKeywordCNN

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

模型架构与训练

- 输入: $39 \times T$ MFCC 特征图
- 4 个卷积块 (通道数
 $1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128$)
- Conv2d + BatchNorm + ReLU +
MaxPooling
- AdaptiveAvgPool(2,2) + Dropout(0.3) +
Linear $\rightarrow 10$
- 总参数量: 102,522
- 训练: AdamW (lr=0.001), 含数据增强,
早停 patience=20



纯净语音混淆矩阵 (准确率 95.0%, 19/20)

1 个错误: 数字 2 误判为 6

识别结果对比与噪声鲁棒性




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

纯净语音识别结果

方法	维度	准确率
MFCC-stat + KNN	26 维	80.0%
MFCC+ Δ/Δ^2 +GMM	39 维	100.0%
TinyKeywordCNN (102k)	39 维	95.0%

噪声鲁棒性 (SNR-Accuracy)



- GMM: 20 条验证样本全部正确
- CNN: 1 个误判 (2 $\rightarrow$ 6), KNN: 4 个混淆

KNN/GMM 为 20 次重复均值; CNN 为单次测试, 统计意义不完全等价

- 准确率整体随 SNR 提高呈上升趋势, 但非严格单调; 验证集较小且 CNN 为单次测试, 局部存在波动
- GMM 与 CNN 在 20 dB SNR 时首次达到 90% 以上 (各 91.25%, 95%), KNN 在所有 SNR 下均未达到 90%
- 低 SNR (-10, -5 dB): CNN 数据增强占优; 中高 SNR (≥ 5 dB): GMM 时序建模 + CMVN 占优

总结、局限性与团队分工



已完成工作

- 基于短时能量端点检测的自动语音切分
- 完整 MFCC 特征提取 (预加重 $\rightarrow$ 分帧 $\rightarrow$ FFT $\rightarrow$ Mel 滤波 $\rightarrow$ DCT)
- 传统方法: KNN + GMM; 深度方法: TinyKeywordCNN
- 混合噪声下 7 级 SNR 鲁棒性评估

核心结论

- ① MFCC 特征对数字语音有良好区分度
- ② 动态特征、序列建模与 CMVN 归一化显著提升传统方法性能
- ③ 纯净语音和中高 SNR 下 GMM 更优; 低

局限性

- 验证集仅 20 样本, 统计意义有限
- 单一混合噪声类型, 未测试各噪声单独影响
- 未进行说话人交叉验证
- 深度学习未尝试残差、注意力等架构

谢谢



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

